

ALIBABA CLOUD

阿里云
专有云

AI Stack用户指南

产品版本：V2.14.0
文档版本：20260529

 阿里云

法律声明

阿里云提醒您在阅读或使用本文档之前仔细阅读、充分理解本法律声明各条款的内容。如果您阅读或使用本文档，您的阅读或使用行为将被视为对本声明全部内容的认可。

1. 您应当通过阿里云网站或阿里云提供的其他授权通道下载、获取本文档，且仅能用于自身的合法合规的业务活动。本文档的内容视为阿里云的保密信息，您应当严格遵守保密义务；未经阿里云事先书面同意，您不得向任何第三方披露本手册内容或提供给任何第三方使用。
2. 未经阿里云事先书面许可，任何单位、公司或个人不得擅自摘抄、翻译、复制本文档内容的部分或全部，不得以任何方式或途径进行传播和宣传。
3. 由于产品版本升级、调整或其他原因，本文档内容有可能变更。阿里云保留在没有任何通知或者提示下对本文档的内容进行修改的权利，并在阿里云授权通道中不时发布更新后的用户文档。您应当实时关注用户文档的版本变更并通过阿里云授权渠道下载、获取最新版的用户文档。
4. 本文档仅作为用户使用阿里云产品及服务的参考性指引，阿里云以产品及服务的“现状”、“有缺陷”和“当前功能”的状态提供本文档。阿里云在现有技术的基础上尽最大努力提供相应的介绍及操作指引，但阿里云在此明确声明对本文档内容的准确性、完整性、适用性、可靠性等不作任何明示或暗示的保证。任何单位、公司或个人因为下载、使用或信赖本文档而发生任何差错或经济损失的，阿里云不承担任何法律责任。在任何情况下，阿里云均不对任何间接性、后果性、惩戒性、偶然性、特殊性或刑罚性的损害，包括用户使用或信赖本文档而遭受的利润损失，承担责任（即使阿里云已被告知该等损失的可能性）。
5. 阿里云网站上所有内容，包括但不限于著作、产品、图片、档案、资讯、资料、网站架构、网站画面的安排、网页设计，均由阿里云和/或其关联公司依法拥有其知识产权，包括但不限于商标权、专利权、著作权、商业秘密等。非经阿里云和/或其关联公司书面同意，任何人不得擅自使用、修改、复制、公开传播、改变、散布、发行或公开发表阿里云网站、产品程序或内容。此外，未经阿里云事先书面同意，任何人不得为了任何营销、广告、促销或其他目的使用、公布或复制阿里云的名称（包括但不限于单独为或以组合形式包含“阿里云”、“Aliyun”、“万网”等阿里云和/或其关联公司品牌，上述品牌的附属标志及图案或任何类似公司名称、商号、商标、产品或服务名称、域名、图案标示、标志、标识或通过特定描述使第三方能够识别阿里云和/或其关联公司）。
6. 如若发现本文档存在任何错误，请与阿里云取得直接联系。

通用约定

格式	说明	样例
 警告	适用于可能会产生风险的场景。介绍用户在操作前就必须充分了解的信息、操作前必须要注意的事项或已具备的条件。	 警告 重启操作将导致业务短暂中断，建议您在业务低峰期执行重启操作，或确保已完成数据备份。如有必要，请联系阿里云技术支持提供协助。
 重要	在操作前需要用户了解的提示信息、补充信息、注意事项、限制信息等。	 重要 再次登录系统时，您需要修改登录账户的初始密码。
 说明	用于额外的补充说明、最佳实践、窍门等，不是用户必须了解的信息。	 说明 您也可以通过按Ctrl+A选中全部文件。
>	多级菜单递进。	单击设置> 网络> 设置网络类型。
粗体	表示按键、菜单、页面名称等UI元素。	在结果确认页面，单击确定。
Courier字体	命令或代码。	执行 <code>cd /d C:/window</code> 命令，进入Windows系统文件夹。
斜体	表示参数、变量。	<code>bae log list --instanceid</code> <code>Instance_ID</code>
[] 或者 [a b]	表示可选项，至多选择一个。	<code>ipconfig [-all -t]</code>
{ } 或者 {a b}	表示必选项，至多选择一个。	<code>switch {active stand}</code>

目录

1.安全使用	08
2.概述	12
3.使用须知	13
4.快速入门	14
4.1. 登录AI Stack控制台	14
4.2. 查看模型仓库	14
4.3. 查看镜像库	15
4.4. 部署在线服务	15
4.5. 查看节点监控	20
4.6. 查看告警管理	21
4.7. 修改节点root密码	22
5.概览	23
6.推理服务	25
6.1. 模型网关	25
6.1.1. 功能概述	25
6.1.2. 创建模型网关	25
6.1.3. 修改模型网关	26
6.1.4. 删除模型网关	27
6.2. 模型仓库	27
6.2.1. 功能概述	27
6.2.2. 模型介绍	27
6.2.3. 查看模型仓库	29
6.3. 镜像库	30
6.3.1. 功能概述	30
6.3.2. 查看镜像库	30
6.4. 在线服务	31

6.4.1. 功能概述	31
6.4.2. 部署在线服务	31
6.4.3. 删除在线服务	35
6.4.4. 停止在线服务	36
6.4.5. 启用在线服务	36
6.4.6. 管理在线服务	36
6.5. 模型观测	37
6.5.1. 功能概述	37
6.5.2. 查看模型监控数据	38
7.模型体验	39
7.1. 功能概述	39
7.2. 文本模型	39
7.3. 视觉模型	40
7.4. 知识库	41
7.5. RAG应用体验	42
8.监控运维	44
8.1. 节点监控	44
8.1.1. 功能概述	44
8.1.2. 查看基础信息监控	44
8.1.3. 查看GPU信息监控	45
8.2. 告警管理	46
8.2.1. 功能概述	46
8.2.2. 告警列表	46
8.2.3. 告警通知	46
8.3. 安全规则	48
8.4. 网络监控运维	50
8.4.1. CPN监控	50
8.4.2. CPN告警	51

8.4.3. SYSLOG日志	51
9.应用中心	52
9.1. 应用商店	52
9.2. 我的应用	59
9.3. 容器集群管理	64
9.4. 授权信息	64
10.节点管理	67
10.1. 功能概述	67
10.2. 远程登录	67
10.3. 修改root用户密码	67
10.4. 修改主机名	68
11.系统管理	69
11.1. 用户管理	69
11.1.1. 功能概述	69
11.1.2. 创建用户	69
11.1.3. 管理MFA	70
11.1.3.1. MFA概述	71
11.1.3.2. 开启并绑定虚拟MFA设备	71
11.1.3.3. 关闭并解绑虚拟MFA设备	72
11.1.4. 编辑用户	73
11.1.5. 禁用用户	74
11.1.6. 删除用户	74
11.1.7. 重置用户密码	74
11.1.8. 用户角色授权	75
11.2. 操作日志	75
11.3. 授权管理	76
11.4. SP管理	76
11.5. 系统设置	77

11.5.1. 系统版本	77
11.5.2. 自定义配置	78
11.6. API Token管理	79
11.7. 网关API Key管理	80
11.7.1. API列表	80
11.7.2. 调用明细	81
11.7.3. 配置管理	82
12.多机版本	83
12.1. 控制台切换	83
12.2. 创建多机集群	83
12.3. 扩容多机集群	84
12.4. 缩容多机集群	85
12.5. 删除多机集群	85
12.6. 多机在线服务	86
12.7. 多机模型网关	87
12.8. 多机模型观测	88
13.附录	90
13.1. 支持的模型列表	90
13.2. 禁止多点登录	92
13.3. 配置域名登录	92
13.4. 配置HTTPS	93
13.5. 通过AzureAD登录AI Stack	95

1. 安全使用

账号管理

AI Stack的账号管理体系分应用平台层和主机系统层，支持使用者按需更新凭证。

- 应用平台层面预置了admin管理员账户及初始密码，首次登录时会强制要求用户修改默认密码，确保账户控制权的安全性；并依照合规及安全管理要求，如每7天定时更换包括admin在内的应用平台的用户账户密码。
 - 初始账户：admin
 - 密码：admin123
- 主机系统层预置root用户账户及固定密码，建议用户在设备初始化阶段主动更新密码，避免长期使用默认凭证带来的风险。并依照合规及安全管理要求，如每7天定时更换包括root在内的主机系统的用户账户密码。
 - 初始账户：root
 - 密码：AIStack@123
- 除上述两类预置账户外，系统未配置任何其他默认密钥或隐藏凭证，需通过修改应用平台以及主机系统的用户凭证并定期维护，不建议用户主动新增用户、凭证。以保护系统安全。

日志存储

AI Stack具有平台管控、监控以及系统安装的日志，确保系统运行状态及操作行为的完整记录与可追溯性。具体配置如下：

- 管控与监控日志
 - 存储路径：`/usr/bin/aioController/log`。
 - 单文件容量限制：单个日志文件最大为100MB，文件体积达到阈值后自动分割生成新文件。
 - 总量管控：最多保留40个历史日志文件（总容量上限4GB），采用滚动覆盖机制，超限后自动删除最早日志以释放存储空间。
 - 用途：实时记录平台操作记录、设备运行状态、管控操作及异常告警信息，为运维监控与故障排查提供完整数据支持。
- 系统安装日志
 - 存储路径：`/usr/local/aio_clonescripts/aio_clone.log`。
 - 特性：独立记录系统初始部署、软件安装及配置过程中的关键操作与执行结果。
 - 用途：用于回溯安装流程、诊断部署异常或版本更新问题。
- 运行日志：
 - 存储路径：位于执行命令时所在目录中的aio-ops-start.log文件。
 - 特性：完整记录了aio-ops各项检测能力所执行的运维命令及其运行结果。
 - 用途：支持对AI Stack上各类服务与组件的健康状况进行快速定位与分析，涵盖平台服务、容器运行时、GPU、操作系统、内存、磁盘以及硬件设备等方面，从而提升系统运维效率与故障排查能力。

资源隔离

AI Stack采用单租户的架构，所有硬件资源与软件服务栈归属于单一用户，无多租户间的虚拟化共享或逻辑分割。因此，资源由管理员全权管控。所有模型服务强制以containerd容器形式部署。

使用者需要通过合理的账户权限管理，对提交到AI Stack的任务、镜像、模型、代码等做好检查和信任确认，避免被投毒或恶意攻击引起AI Stack故障、数据丢失、加密勒索等。

运行安全

本产品以支持您在由您掌握完整控制权的物理、网络环境下，快速部署、调用大模型推理能力为目的提供，且不同版本可能具备不同的运行安全产品能力，您有义务仔细阅读本协议以及我们产品及服务文档的说明文件（如用户手册），根据运行环境和业务安全需求采取必要安全措施，履行安全保护义务，保障产品免受干扰、破坏或者未经授权的访问，防止产品发生数据泄露或者被窃取、篡改。

- 为确保设备运行环境的安全性并降低外部攻击风险，AI Stack应运行于物理隔离的内部局域网，不支持以直接、间接的方式暴露在互联网。
- AI Stack支持通过配置网络安全规则强化访问控制，仅开放业务必需的端口，规避安全攻击。
- AI Stack不推荐在其系统上安装、运行其他非阿里云组件、服务、软件，以规避投毒或引入系统不稳定因素。
- AI Stack除本身的基础安全功能，支持与其他生态联合组合安全解决方案以更好地保障AI Stack使用的安全。

合规安全

AI Stack支持基本的合规要求如采用基于角色概念（RBAC）的权限访问控制，遵循三权分立原则，通过角色互斥与权限最小化设计保障系统安全。用户角色分为管理员、安全管理员、应用管理员和审计管理员四个角色。管理员与安全管理员互斥，任一角色无法独揽用户创建、权限分配与账号熔断权。应用管理员仅持有业务必需权限，无法触及系统底层或用户管理体系。其他合规要求建议结合对应解决方案。

具体角色定义如下：

- **管理员：**
 - 一台AI Stack只有一个管理员。
 - 具有远程登录AI Stack，提交镜像，部署在线服务，创建/管理用户（创建安全管理员，创建审计管理员）的权限。
- **安全管理员：**
 - 一台AI Stack只有一个安全管理员。
 - 具有禁用管理员的权限，禁用后管理员账号无法登录。
 - 具有创建/管理用户的权限。
 - 一经创建无法删除。
- **审计管理员：**
 - 一台AI Stack只有一个审计管理员。
 - 具有审计日志的权限。
 - 一经创建无法删除。
- **应用管理员：**
 - 一台AI Stack有多个应用管理员。
 - 具有查看静态数据（模型列表，镜像列表），查看以及使用运行中的服务（模型体验chatbox）和修改自身密码的权限。

安全使用条款

1. 适用范围及定义

1.1 您在使用阿里云飞天（杭州）云计算技术有限公司（“我们”）提供的、或通过我们的合作伙伴提供的AI Stack产品，应当仔细阅读并遵守本条款。请您务必审慎阅读、充分理解各条款的内容，特别是免除或者限制责任的条款、法律适用和争议解决条款以及其他涉及您重大权益影响的条款，这些条款将以粗体、下划线标识，您应重点阅读。如您对本条款有任何疑问，可以通过我们提供的联系方式与我们沟通咨询。

1.2 “AI Stack”：是指预置了部分开源模型的软硬一体机。

1.3 “三方模型”：是指AI Stack内置的或者由您自行下载部署的由第三方服务商开发并提供的模型或技术服务。

1.4 “三方产品”：是指AI Stack中接入的您或第三方供应商开发的AI应用、软件或服务。

2. 知识产权

2.1 如果您通过AI Stack对三方模型进行优化、调试、训练和其他精调（统称“精调”）的，精调模型的知识产权归属以您选取的三方模型服务商提供的许可协议或其他类似约束类协议约定为准。

2.2 如您或者您的用户使用三方模型生成内容的，前述合成内容是否具有知识产权、以及知识产权的归属，应由您或您的用户自行判断及处理。您应当知悉并理解，三方模型生成的内容无法完全避免知识产权等侵权风险，特别是在您及您的下游客户（如有）输入涉及未授权文本、知名IP等内容，侵权风险也会随之增加。您需仔细评估后再进行对外商业化使用，您需确保您及您的下游用户（如有）合法合理进行输入、输出行为，并自行承担一切后果。

3. 监管合规

3.1 对于三方模型，您需核查其是否履行监管备案义务。如未完成，您调用该模型能力将仅可用于内部研究及测试目的；如完成，您基于该三方模型能力进一步开发应用后向公众提供服务的，您需根据法律法规要求履行监管备案义务（如涉及）。

3.2 如您利用本产品自行开发模型/模型应用、对外提供服务等，作为技术支持者或服务提供者，您应自行遵守《互联网信息服务管理办法》《互联网信息服务深度合成管理规定》《生成式人工智能服务管理暂行办法》等法律、行政法规及规章制度。若您所提供的服务具有舆论属性或社会动员能力，您将依法开展安全评估/备案和算法备案。

4. 安全义务

4.1 您理解并知悉，AI Stack允许您上传或基于AI Stack应用中心等自行下载或部署第三方服务商开发并提供的三方模型/产品。针对任何三方模型/产品，您应在正式使用前仔细阅读由三方服务商提供的《服务协议》《开源许可协议》《开源许可证》或其他约束类协议并审慎评估风险，并确保在同意前述条款的前提下再开始使用相应服务。您在使用三方模型/产品过程中产生的任何争议或责任，与我们无关；若您违反前述条款约定的行为导致我们承担任何侵权诉讼、或其他责任的，您应向我们承担赔偿责任。

4.2 您理解并同意我们既不构成现行法律法规下的深度合成服务提供者/生成式人工智能服务提供者，也不构成深度合成技术支持者。您理解当前与三方模型相关的技术无法百分之百保证模型训练服务及涉及模型的安全性、可靠性、可用性、持续稳定性等，同时我们也无法保证其生成内容的准确性、可靠性、无错误性等，您应当自行判断并承担因使用三方模型引起的风险。

4.3 您理解并同意，三方模型可能无法真正理解您上传的您数据或相关内容，因此其同样无法判断或识别潜在的风险和伦理问题。因此，AI Stack预置或您通过其下载的三方模型输出的任何内容均不能视为对您做出的建议。您需要根据自身实际情况作出独立判断，特别是在专业问题（如医疗、金融、法律等）方面，我们不承担因此产生的任何直接或间接损失。

4.4 您通过我们提供的产品，上传、存储、加工、下载、分发以及通过其他方式处理的数据，均为您的业务数据（简称“客户业务数据”），您对此拥有完全的控制权。

4.5 您应当基于数据的级别和类别选择合适的数据安全策略和采取必要的数据安全措施。本项目的数据安全义务包括数据传输安全、数据存储安全、数据迁移安全、数据安全管理等，其中数据迁移安全指数据在本项目的迁入迁出安全，数据安全是指对上云业务数据和个人信息采取加密存储、备份等数据保护措施，对能够接触到业务数据和信息的系统建设或运维人员进行严格审批等安全措施。阿里云在现有技术的情况下，尽最大合理商业努力就产品功能进行完整、准确的描述，并基于产品文档说明的功能为运营方提供数据处理的工具。如阿里云基于实际合作需要，与您另行签署数据处理协议的，双方责任以数据处理协议为准。

4.6 本产品以支持您在由您掌握完整控制权的物理、网络环境下，快速部署、调用大模型推理能力为目的提供，且不同版本可能具备不同的运行安全产品能力，您有义务仔细阅读本协议以及阿里云产品及服务文档的说明文件（如用户手册），根据运行环境和业务安全需求采取必要安全措施，履行安全保护义务，保障产品免受干扰、破坏或者未经授权的访问，防止产品发生数据泄露或者被窃取、篡改，您通过AI Stack产品功能部署或以其他任何形式部署的所有应用或服务，其安全性、合规性及运行稳定性均由您独立承担全部责任。

5. 产品生命周期

您应不定期，或在收到阿里云通知后及时查看阿里云官网（或其他阿里云的通知方式），获知关于产品生命周期的公告信息，了解对应产品的状态，及时做好业务规划。您应根据公告或阿里云通知落实替代方案（包括但不限于将软件更新到指定版本、更换替代软件/硬件）。如更新版本或替代软件/硬件附随协议，该等附随协议将作为本协议的有效组成部分。该种替代方案可能增加必要的成本，包括但不限于为落实替代方案更换或增加必要的配套软/硬件，以及阿里云在协议约定外额外提供的技术服务成本，相应费用由您承担。

6. 其他声明

6.1 维护管理和应急响应。如您购买阿里云提供的运维服务/安全服务的，阿里云按照协议约定，在您授权范围内提供维护管理和应急响应支持。如您未购买阿里云提供运维服务/安全服务的，阿里云不负责提供前述支持服务。

6.2 产品完整性。除另有约定外，针对本协议项下的“AI Stack产品”，在适用法律允许的最大范围内，在阿里云与您之间，阿里云不做任何形式的保证，无论是明示的、暗示的、法定的还是其他形式的，并且特别排除所有暗示保证，包括但不限于适销性、适用于特定目的或非侵权的任何暗示保证。阿里云产品是“按现状”和“可获得”的形式提供的，且完全排除任何形式的保证。

网络安全

AI Stack本身支持通过预置网络安全规则进行网络安全防护，控制主机最小粒度暴露和访问。默认访问矩阵为：

方向	端口范围	用途	安全控制和建议
从外到内	30000-35000	模型服务的运行端口。	在开启推理服务时开启Token认证，由于目前不支持HTTPS，为保障通信安全，建议在信任网络中使用。
从外到内	80	AI Stack控制台的访问端口。	使用应用平台账户密码进行认证，由于目前不支持HTTPS，且该服务具备高权限，建议严格限制暴露范围。
从外到内	22	AI Stack SSH访问端口。	通过系统主机账户密码认证的高权限服务，建议严格限制暴露范围。
从内到外	默认拒绝所有	防止被反向控制，多机场景下需额外开放其他机器的80、22以及30000-35000端口。	默认不修改，如有增加场景，需精细化放通。

2. 概述

背景信息

在大模型技术迅速发展的背景下，用户面临着算力需求激增、资源利用率低、运维复杂、难上手等多重挑战。AI Stack产品通过高性能的硬件设计，单机即可运行DeepSeek无损精度满血版；通过深入算子、算法框架层的优化，推理性能较开源社区版本提升50%。同时，产品出厂预装主流开源大模型，简单的白屏操作，用户开箱即可享用大模型服务，极大地降低了大模型业务上手的成本，助力用户智能化转型。AI Stack单机版定位为专为大模型场景设计的软硬一体化解决方案，旨在为用户提供高性能、易部署的AI算力平台。

功能概述

AI Stack在功能架构上从上至下分为控制台页面、管控层及资源层三层：

• 上层（控制台页面）

- 是用户交互核心，提供可视化操作界面，聚焦用户管理、告警展示、节点状态监控、模型部署等业务功能。
- 提供轻量化设计，不涉及底层逻辑，仅通过API与中层交互，降低前端复杂度。

• 中层（管控层）

- 是业务逻辑中枢，承担鉴权、监报告警、数据库管理、服务生命周期调度等核心管控功能。
- 承上启下：将上层用户请求转化为下层可执行指令，同时汇总底层状态反馈至上层。

• 下层（资源层）

- 是资源调度与执行引擎，直接管理GPU资源分配、模型存储路径、容器实例启停等物理/虚拟化操作。
- 高可靠性要求：需保障资源调度的实时性与稳定性（如GPU任务无中断迁移）。

3.使用须知

本文介绍使用AI Stack前您需要了解的内容。

使用说明

- AI Stack将内置用户角色，并提供用户管理功能，以实现权限的分层管理；用户角色包括管理员、安全管理员、应用管理员和审计管理员。不同角色具备不同的产品使用权限。具体权限区分请参见对应操作文档的前提条件部分。
- AI Stack提供的预置系统镜像不允许任何用户删除。
- AI Stack提供的预置系统模型不允许任何用户删除。
- 管理员用户初次登录AI Stack控制台时，出于系统安全性考量会强制要求修改密码并重新登录。
- 推荐使用Chrome和Firefox浏览器。具体版本限制如下：
 - Chrome浏览器：推荐使用108及以上版本，最低版本不低于87.0.4280.88版本。
 - Firefox浏览器：推荐使用91.0及以上版本，最低版本不低于91.0版本。

说明

- 推荐优先使用上述浏览器的最新版本。
- 不建议使用除Chrome和Firefox以外的浏览器。

- CPU实例主要用于对客提供基础CPU实例，可用于构建一方/三方AI应用。支持面向CPU节点的包括节点管理和监控运维。

4. 快速入门

4.1. 登录AI Stack控制台

本文介绍如何登录AI Stack控制台。

前提条件

② 说明

目前支持以IP、域名或AzureAD方式登录AI Stack控制台，默认以IP地址登录。

- 如果需要以域名方式登录，请先参考[配置域名登录](#)配置域名后登录，域名登录的格式为HTTP://域名。
- 如果需要通过AzureAD登录AI Stack控制台，请参考[通过AzureAD登录AI Stack](#)进行配置后登录。

- 登录AI Stack控制台前，确认您已从部署人员处获取AI Stack所处部署节点的IP地址并且能够网络连通。
- 推荐使用最新版本的Chrome浏览器。
- 如果需要开启禁止多点登录功能，请参见[禁止多点登录](#)设置。

操作步骤

1. 在浏览器地址栏中，输入AI Stack所处部署节点的IP地址，按回车键。
2. 输入正确的用户名及密码。

② 说明

- 首次登录AI Stack控制台时，会为用户提供预置的管理员账号及密码，登录完成后会强制用户进行密码修改。为提高安全性，密码长度必须为12位以上，且包含英文字母大小写、阿拉伯数字和特殊符号（感叹号(!)、at(@)、井号(#)、美元符号(\$)、百分号(%)等）中的三项。
- 设置的新密码不得含有alibaba、1688、aistack、aliyun、alios等关键字。
- 设置的新密码不得与最近 5 次历史密码重复。

3. 勾选我已阅读《产品使用条款》，并同意条款内容。
4. 单击登录。
5. 开始使用AI Stack产品服务，进入概览页面。

② 说明

如果已开启禁止多点登录功能，同一账号在其他地点登录时，已登录的账号会自动退出会话，并提示用户该账户在其他地区已被登录，可能存在账户被盗的风险。

4.2. 查看模型仓库

本文主要向您介绍如何查看AI Stack模型仓库。

前提条件

已成功登录AI Stack控制台，具体操作请参见对应文档。

使用限制

仅支持对自定义模型进行删除操作。

查看模型仓库操作步骤

1. [登录AI Stack控制台](#)。
2. 在顶部菜单中单击**推理服务**。
3. 在左侧菜单栏单击选择**推理服务->模型仓库**。
4. 查看模型仓库内模型的相关信息。

模型仓库

模型仓库中展示的是当前服务下已生效的全量系统预置模型和自定义模型。如需上传自定义模型请在操作页面[前往模型仓库](#)。

本产品预置了部分开源模型，请确保在遵守其开源协议的前提下再开始使用相应的模型。 [查看预置模型和对应开源协议](#)

模型名称	启用状态	模型来源	模型Hash值	关联任务	创建时间
katy2	启用	自定义模型	-	0	5月 27, 2025, 10:33:05
katy6	启用	自定义模型	-	0	5月 27, 2025, 10:33:05
katy4	启用	自定义模型	-	0	5月 27, 2025, 10:33:05
katy7	启用	自定义模型	-	0	5月 27, 2025, 10:33:05
katy1	启用	自定义模型	-	0	5月 27, 2025, 10:33:05
katy5	启用	自定义模型	-	0	5月 27, 2025, 10:33:05
katy6	启用	自定义模型	-	0	5月 27, 2025, 10:33:05
katy10	启用	自定义模型	-	0	5月 27, 2025, 10:33:05
katy9	启用	自定义模型	-	0	5月 27, 2025, 10:33:05
katy3	启用	自定义模型	-	0	5月 27, 2025, 10:33:05

共 28 项 < 1 2 3 > 每页显示: 10

4.3. 查看镜像库

本文主要介绍如何查看AI Stack镜像库。

前提条件

已成功登录AI Stack控制台，具体操作请参见对应文档。

使用限制

预置镜像不支持删除，仅支持对自定义镜像进行删除操作。

操作步骤

1. [登录AI Stack控制台](#)。
2. 在顶部菜单中单击**推理服务**。
3. 在左侧菜单栏中选择**推理服务->镜像库**。
4. 查看镜像库内镜像的相关信息。

说明

支持根据镜像的RepoTags判断自定义镜像是容器镜像或应用相关镜像。标签格式：
ai.stack.application="custom"。

镜像库

镜像库展示当前已经生效的全量系统预置镜像和自定义镜像。如需新增自定义镜像请在操作页面[手动添加镜像](#)。

镜像名称	Tag	RepoTags	镜像大小	关联任务	镜像来源	镜像Hash值	创建时间
docker.io/library/tensorflow/tensorflow:2.10.0-gpu	1.3.1-pytorch	docker.io/library/tensorflow/tensorflow:2.10.0-gpu	38132269056	0	系统镜像	bc0e0ef208140200	5月 26, 2025, 14:27:45

共 1 项 < 1 > 每页显示: 10

4.4. 部署在线服务

本文主要介绍如何部署AI Stack在线服务。

背景信息

- 在线服务仅限管理员用户创建或删除，同时管理员可以访问所有的在线服务。
- 应用管理员可以访问所有的在线服务。
- 在线服务之间互相隔离。

前提条件

已成功登录AI Stack控制台，具体操作请参见对应文档。

操作步骤

1. 以管理员[登录AI Stack控制台](#)。
2. 在顶部菜单中单击**推理服务**。
3. 在左侧菜单栏中选择**推理服务 > 在线服务**。
4. 单击左上角的**部署服务**，进入在线服务配置填写界面。
 - i. 配置基本信息。

配置项	是否必选	说明
服务名称	是	请填写在线服务的名称，不超过256字符长度。
描述	否	在线服务的描述。

- ii. 配置信息。

配置项	是否必选	说明
GPU厂商	是	目前仅支持 APG 、 Ascend 和 Nvidia 。  说明 具体厂商将根据多机版集群中节点所支持的GPU厂商进行展示。
节点列表	是	根据所选择的GPU厂商展示节点。

模型服务配置	是	支持高性能部署和自定义配置部署。 ■ A-Speed 高性能部署：基于阿里云AI Stack A-Speed 加速套件，提供深度优化的加速镜像，在创建流程中仅能选择支持该框架的镜像和模型。 ■ 自定义配置：可按照自身场景灵活配置部署中所需要的配置。
实例规格	否	可选，当模型服务配置选择A-Speed 高性能部署时，需要配置该参数。 ■ 极简配置（1卡，8 CPU） ■ 精简配置（2卡，48 CPU） ■ 基础配置（4卡，48 CPU） ■ 标准配置（8卡，96 CPU） ■ 专业配置（16卡，256 CPU）
模型	否	可选，当模型服务配置选择A-Speed 高性能部署时，需要配置该参数。在线服务依托的具体底层模型。
CPU数量	否	可选，当模型服务配置选择自定义配置时，需要配置该参数。部署在线服务时使用的CPU数量。
内存容量	否	可选，当模型服务配置选择自定义配置时，需要配置该参数。 部署在线服务时使用的内存容量。
资源类型	否	可选，当模型服务配置选择自定义配置时，需要配置该参数。 ■ GPU共享模式 ■ GPU独享 ■ CPU模式
算力配置	否	可选，当模型服务配置选择自定义配置且资源类型选择GPU共享模式时，需要配置该参数。 表示给本次部署的在线服务分配的算力资源，例如50%步长。

显存配置	否	可选，当模型服务配置选择自定义配置且资源类型选择GPU共享模式时，需要配置该参数。 表示给本次部署的在线服务分配的GPU显存，例如32GB。
GPU卡	否	可选，当模型服务配置选择自定义配置且资源类型选择GPU共享模式时，需要配置该参数。 请下拉选择符合本次部署的在线服务资源要求的GPU卡。
GPU数量	否	可选，当模型服务配置选择自定义配置且资源类型选择GPU独享时，需要配置该参数。 部署在线服务时使用的GPU数量。
共享内存容量	否	可选，当模型服务配置选择自定义配置时，需要配置该参数。 部署在线服务时使用的共享内存。
选择模型	是	可选，当模型服务配置选择自定义配置时，需要配置该参数。部署在线服务时使用底层模型。 - 系统模型：下拉选择AI Stack系统自带的模型。 - 自定义模型：选择自定义模型。 说明 平台无法保障自定义模型和系统镜像的兼容性，需要用户为自定义模型提供兼容性相匹配的模型框架服务镜像，以及提供对应镜像的启动命令。

选择镜像	是	可选，当模型服务配置选择自定义配置时，需要配置该参数。部署在线服务时使用的推理框架镜像。 ■ 系统镜像 ■ 自定义镜像  说明 平台无法保障系统模型和自定义镜像的兼容性，需要用户为系统模型提供兼容性相匹配的自定义模型框架服务镜像，以及提供相对应镜像的启动命令。
服务端口	否	可选，当模型服务配置选择自定义配置时，需要配置该参数。在线服务暴露的端口。
启动命令	是	可选，当模型服务配置选择自定义配置时，需要配置该参数。部署在线服务需要运行的启动命令。

iii. 高级配置。

配置项	是否必选	说明
禁用seccomp	否	勾选后，启动在线服务会增加seccomp=unconfined配置，该操作会允许当前创建的服务访问操作系统内核高危、敏感内容。
覆盖entrypoint	否	勾选后，启动服务时“启动命令”会覆盖镜像原有的entrypoint。
KVCache 加速	否	当模型服务配置是 A-Speed 高性能部署 同时模型选择Qwen3-235B时，展示本参数。 打开后启用KVCache加速功能。
KVCache 存储	否	当模型服务配置是 A-Speed 高性能部署 同时模型选择Qwen3-235B时，展示本参数。 启用时使用APFS，关闭时使用本地文件系统。
启用API Key	否	启用后会提供鉴权能力。系统会默认存储加密后的API Key，仅供模型观测服务使用。
API Key	否	请输入API Key并妥善保存。

5. 单击创建，即可拉起一个用于模型交互的在线服务。

4.5. 查看节点监控

本文主要介绍如何查看节点监控信息。

前提条件

- 已成功登录AI Stack控制台，具体操作请参见对应文档。
- 需要确认AI Stack运行的物理节点时钟源已进行同步。


操作步骤

- 登录AI Stack控制台。
- 在顶部菜单中单击**监控运维**。
- 在左侧菜单栏选择**监控运维->节点监控**。

4. 查看节点的基础监控，可以选择按照不同的时间间隔查看CPU使用率、内存使用率、负载等基础信息的监控。

节点监控

展示服务器基础中相关监控信息。



5. 单击右侧**GPU监控**，可以选择按照不同的时间间隔查看节点上所有GPU卡的使用率、温度、功率等信息。

节点监控

展示服务器基础中相关监控信息。



4.6. 查看告警管理

本文主要介绍如何查看AI Stack告警管理信息。

前提条件

- 已成功登录AI Stack控制台，具体操作请参见对应文档。
- 需要确认AI Stack运行的物理节点时钟源已进行同步。

查看节点监控操作步骤

1. [登录AI Stack控制台](#)。
2. 在顶部菜单中单击**监控运维**。
3. 在左侧菜单栏中选择**监控运维->告警管理**。

4. 可以查看到节点所有告警信息的名称、告警级别、告警内容、告警发生的次数、开始时间和结束时间。

告警管理

显示全部的故障告警。

告警ID	告警名称	告警级别	告警内容	告警来源	告警设备	告警次数	告警开始时间	告警结束时间
28	CONTAINER_RESOURCE_LIMIT_ERR	P4 提示	container: 9eb19ec35bbe, Name: appservice no cp...	10.23	10.23	1	5月 26, 2025, 18:02:48	5月 26, 2025, 18:02:48
27	CONTAINER_RESOURCE_LIMIT_ERR	P4 提示	container: 654c22378950, Name: kube-system/kub...	10.2	10.2	1	5月 26, 2025, 17:02:48	5月 26, 2025, 17:02:48
26	CONTAINER_RESOURCE_LIMIT_ERR	P4 提示	container: 9eb19ec35bbe, Name: appservice no cp...	10.2	10.2	6	5月 26, 2025, 17:02:48	5月 26, 2025, 23:04:35
25	CONTAINER_RESOURCE_LIMIT_ERR	P4 提示	container: 61011d906e7, Name: kube-system/csi-L...	10.2	10.2	1	5月 26, 2025, 17:02:48	5月 26, 2025, 17:02:48
24	CONTAINER_RESOURCE_LIMIT_ERR	P4 提示	container: 01ae11aa0b4c, Name: kube-system/csi-L...	10.2	10.2	1	5月 26, 2025, 17:02:48	5月 26, 2025, 17:02:48
23	CONTAINER_RESOURCE_LIMIT_ERR	P4 提示	container: 654c22378950, Name: kube-system/kub...	10.23	10.23	7	5月 26, 2025, 17:02:48	5月 26, 2025, 23:04:35
22	CONTAINER_RESOURCE_LIMIT_ERR	P4 提示	container: 61011d906e7, Name: kube-system/csi-L...	10.2	10.2	7	5月 26, 2025, 17:02:48	5月 26, 2025, 23:04:35
21	CONTAINER_RESOURCE_LIMIT_ERR	P4 提示	container: f544f5e0b61d, Name: asim-rs44t no cp...	10.23	10.2	1	5月 26, 2025, 17:02:48	5月 26, 2025, 17:02:48
20	CONTAINER_RESOURCE_LIMIT_ERR	P4 提示	container: 01ae11aa0b4c, Name: kube-system/csi-L...	10.23	10.23	7	5月 26, 2025, 17:02:48	5月 26, 2025, 23:04:35
19	CONTAINER_RESOURCE_LIMIT_ERR	P4 提示	container: e0b07e177476, Name: appservice no cp...	10.23	10.2	1	5月 26, 2025, 17:02:48	5月 26, 2025, 17:02:48

共 28 项 1 2 3 每页显示: 10

4.7. 修改节点root密码

本文主要向您介绍如何修改物理机root账户密码。

前提条件

- 已成功登录AI Stack控制台，具体操作请参见对应文档。
- AI Stack运行的物理节点处于正常状态。
- 当前登录用户具有管理员权限。

操作步骤


- 登录AI Stack控制台。
- 在顶部菜单栏中单击节点管理。
- 可以查看到节点名称、主机名、节点状态、配置、IP地址等信息。
- 单击操作列表中的修改密码。
- 在修改密码的界面中填写新密码和确认密码。
- 单击确定，即可修改节点root账户的密码。

5.概览

统计并展示当前节点概览信息，包括节点资源信息、服务器硬件资源用量统计（CPU、内存、GPU）、推理任务资源使用情况等。

操作步骤

1. 以管理员登录AI Stack控制台。
2. 工作台显示如下：



区域	说明
顶导-左上角	支持切换单机版/多机版。
顶导菜单	展示AI Stack的功能模块菜单。
资源数据	统计并展示AI Stack中集群和节点的数量。
资产数据	统计并展示AI Stack中模型和镜像的数量。
资源消耗统计	统计并展示CPU使用率、内存使用率和GPU使用率。

应用分析	- 以圆形环状展示已导入应用数和已部署应用数。 - 支持按CPU、内存或GPU展示应用资源的消耗量。
任务资源消耗统计	以列表形式统计并展示任务的资源消耗量。
告警监控	以环状图形式展示P1、P2、P3和P4的告警数量，右侧以列表形式显示告警详情。  说明 已修复的告警将不再显示。
业务数据	统计并展示AI Stack中在线服务和应用的数量。
快捷导航	- 展示功能菜单项的快捷入口。 - 展示最近访问的功能菜单项入口。
	支持切换系统语言，支持简体中文、English和繁體中文三种系统语言。
	- 显示当前登录的用户名、角色、当前版本。 - 支持修改密码、退出登录和查看产品使用条款。

6.推理服务

6.1. 模型网关

6.1.1. 功能概述

功能说明

模型网关是一个专门面向大模型推理服务的产品，通过统一的接入层协议，实现对AI推理实例进行智能负载均衡、流量调度、安全合规、服务质量保障等核心特性。同时提供对多种AI推理服务的标准化接入、统一管理和高效调度，具备长连接、容错、重试以及限流等多种核心技术能力。

应用场景

用户使用模型网关对后端在线推理服务进行负载均衡。

技术特点

通过模型推理网关接收客户端的推理请求并分发给后端多副本推理服务，从而实现推理服务负载均衡、流量调度等功能。

前提条件

需确保后端服务在线且模型已成功加载并运行。

6.1.2. 创建模型网关

背景信息

AI Stack控制台单机版和多机版下模型网关信息互相不可见。

前提条件

- AI Stack控制台至少存在一个单机在线推理服务。
- （可选）如果开启API-Key功能，请提前创建API-Key，具体请参见[API列表](#)。

操作步骤

1. 以应用管理员[登录AI Stack控制台](#)。
2. 在顶部菜单栏单击[推理服务](#)。
默认进入模型网关页面。
3. 单击左上角的[创建模型网关](#)，进入模型网关配置填写界面。

配置项	是否必选	说明
网关名称	是	模型网关的名称。
网关ID	是	请自定义网关ID，最长32位，大小写字母+数字，首字必须字母。

网关策略	是	模型网关的负载策略。 - 轮询策略 - IP哈希 - 最少连接 - 随即策略
网关API-Key	是	启用后将使用 Synapse 网关支持 API-Key 鉴权，创建后不可关闭。
API-Key策略	否	当网关API Key开启后，需要配置。请选择API-Key的使用策略。 - 全部 - 部分 - 无鉴权
API-Key	否	当API-Key策略选择部分时，需要配置。 请下拉选择具体的API Key，可选择多个。
后端服务	是	模型网关流量转发的后端服务信息。包括服务IP、端口和模型API-Key。

4. 单击**确定**，即可创建一个用于在线推理服务负载均衡的模型网关。

6.1.3. 修改模型网关

背景信息

AI Stack控制台单机版和多机版下模型网关信息互相不可见。

前提条件

AI Stack控制台至少存在一个单机模型网关。

操作步骤

1. 以应用管理员[登录AI Stack控制台](#)。
2. 在顶部菜单栏单击**推理服务**。
默认进入**模型网关**页面。
3. 在要修改的模型网关条目操作栏单击**选择修改**，进入模型网关配置填写界面。

配置项	是否必选	说明
网关名称	否	模型网关的名称。

网关策略	否	模型网关的负载策略。
后端服务	否	模型网关流量转发的后端服务信息。

4. 单击**确定**，即可对已有模型网关信息进行修改。

6.1.4. 删除模型网关

背景信息

AI Stack控制台单机版和多机版下模型网关信息互相不可见。

前提条件

AI Stack控制台至少存在一个单机模型网关。

操作步骤

1. 以应用管理员[登录AI Stack控制台](#)。
2. 在顶部菜单栏单击**推理服务**。
默认进入**模型网关**页面。
3. 在要删除的模型网关条目操作列单击**删除**。
4. 单击**确定**按钮，即可对已有模型网关进行删除。

6.2. 模型仓库

模型仓库用于管理模型文件，出厂预置部分模型，支持用户按需上传指定模型文件。

6.2.1. 功能概述

功能说明

用于管理模型文件，出厂预置部分行业主流领域模型，支持展示模型资源与在线服务的关联关系。

应用场景

用于用户管理模型文件。

技术特点

通过RBAC权限控制模型访问和操作，提供自动适配推理环境的部署方式。

使用限制

预置系统模型不允许删除。

6.2.2. 模型介绍

本章节介绍AI Stack中内置的Qwen3-Pro模型的功能、性能以及关键技术。

专有云推出了APG专属优化模型Qwen3-Pro，该模型在效果上与Qwen3-VL-235B（开源版）持平，而性能则实现了翻倍提升。

主要增强功能

- Qwen3-Pro通过优化模型结构，在更低的激活参数下实现了与Qwen3-VL-235B（开源版）的模型效果对齐，具备卓越的文本理解与生成能力、深厚的视觉感知与推理能力，以及扩展的上下文长度。
- 专有云针对Qwen3-Pro模型结构，结合APG的硬件特性，进行了深入的算子优化和框架特性研发。在相同的SLO服务等级目标下，其性能可达Qwen3-VL-235B的1.9倍。
- 提供Instruct版本与增强推理的Thinking版本，以实现灵活的按需部署。

模型效果

- **通用能力**：显著提升了指令执行、逻辑推理、文本理解、数学能力、科学知识、编码技能及工具使用效率。
- **增强的多模态推理**：在STEM领域及数学方面表现卓越，具备因果分析能力，并能够基于逻辑和证据提供答案。
- **视觉代理**：操作PC或移动GUI，识别界面元素，理解其功能，调用所需工具，顺利完成任务。
- **长上下文和视频理解**：原生支持256K上下文，且可扩展至1M；能够处理书籍及长达数小时的视频，具备完整的记忆功能和秒级索引能力。
- **高级空间感知**：判断物体的位置、视角以及遮挡情况；提供更为强大的2D定位，并启用3D定位，以支持空间推理和具身AI。
- **文本生成能力**：在主观和开放式任务中，更好地满足用户偏好，从而提高响应的有效性，使生成文本的质量更高。

对比项	Qwen3-Pro	Qwen3-VL-235B（开源版）	解读简化版
MMMU（大规模多学科多模态理解与推理能力）	78.1	78.8	78分是目前已公开模型中所获得的最高梯队分数。
MMMU-PRO（MMMU增强版，精选高难子集）	67.6	67.9	67分代表当前顶尖多模态大模型在高难子集上的合理表现，位于第一梯队。
MATHVISION（MathVista，数学视觉理解与推理能力）	65.5	66.9	在MathVista基准测试中，正确回答了约65%的数学视觉推理题目。
MMBench-En（多模态大模型英文版综合评测）	90.8	90.3	得分90.8分（即90.8%准确率）是一个极为卓越的表现，接近人类的极限水平，甚至超越了人类的平均表现。
RealWorldQA（真实世界常识理解）	79.7	78.7	79.7的RealWorldQA得分处于全球领先水平。

模型性能

单机/集群推理性能是Qwen3-VL-235B的1.9倍。

对比项	Qwen3-Pro	Qwen3-VL-235B
-----	-----------	---------------

1K/1K序列性能对比	整机总吞吐	34200 Token/秒	17900 Token/秒
	支持并发数	2048并发	1024并发
2K/2K序列性能对比	整机总吞吐	27300 Token/秒	13900 Token/秒
	支持并发数	1600并发	800并发

 说明

- 测试模型数据格式为INT8。
- SLO 约束为TTFT < 2秒，TPOT < 100毫秒。

模型输出说明

- 输出说明：Qwen3-Pro仅支持在专有云APG上输出，支持AI Stack与飞天企业版平台承载。
- 输出类型：
 - 推理模型：Qwen3-Pro-Instruct
 - Qwen3-Pro-INT8
 - Qwen3-Pro-VL-BF16

使用限制

专属优化模型Qwen3-Pro不支持在多机节点上的批量部署。

6.2.3. 查看模型仓库

前提条件

已成功登录AI Stack控制台，具体操作请参见对应文档。

使用限制

仅支持对自定义模型进行删除操作。

查看模型仓库操作步骤

1. [登录AI Stack控制台](#)。
2. 在顶部菜单中单击推理服务。
3. 在左侧菜单栏中选择推理服务->模型仓库。
4. 模型仓库中可查看系统模型与自定义模型。
5. 在模型列表上方可单击查看系统模型中开源模型的对外开源协议。

模型仓库

模型仓库中展示的是当前服务器下已经部署的全部系统预置模型和自定义模型。如需上传自定义模型请放置在操作系統/smcg_jvm/cusa/models路径下。

● 本产品预置了部分开源模型，请您确保在遵守对应开源协议的前提下再开始使用相应的模型。查看预置模型和对应开源协议

模型名称	输入模型名称	模型来源	原始Hash值	当前Hash值	关联任务	创建时间
Qwen3-VL-Reranker-8B		自定义模型	-	-	1	2026年04月03日 19:56:20
Qwen3-VL-Reranker-2B		自定义模型	-	-	0	2026年04月02日 21:20:50
Qwen3-VL-Embedding-2B		自定义模型	-	-	1	2026年04月02日 21:19:50
Qwen2.5-VL-7B-Instruct		自定义模型	-	-	1	2026年04月01日 14:17:33
Qwen3-Reranker-4B		自定义模型	-	-	1	2026年04月01日 14:16:33
Qwen3-Embedding-0.6B		自定义模型	-	-	1	2026年04月01日 14:14:33
Qwen3Guard-Stream-8B		自定义模型	-	-	0	2026年04月01日 13:24:52
Qwen3-Coder-480B-A35B-Instruct-INT8		自定义模型	-	-	0	2026年04月01日 13:24:52
Qwen3-235B-A22B-INT8-vllm		自定义模型	-	-	0	2026年04月01日 13:24:52
ckj		自定义模型	-	-	0	2026年04月01日 13:24:52

共 28 项 < 1 2 3 > 每页显示: 10

6. 输入模型名称后，会筛选出符合条件的模型，支持模糊查询。

6.3. 镜像库

镜像库用于管理容器镜像，出厂预置深度优化的容器镜像。

6.3.1. 功能概述

功能说明

用于管理容器镜像，出厂预置深度优化的容器镜像，支持展示容器镜像资源与在线服务的关联关系。

应用场景

用户管理镜像文件。

技术特点

通过RBAC权限控制镜像访问和操作，支持在线服务启动时自动拉起对应容器镜像。

使用限制

预置系统镜像不允许删除。

6.3.2. 查看镜像库

前提条件

已成功登录AI Stack控制台，具体操作请参见对应文档。

使用限制

预置镜像不支持删除，仅支持对自定义镜像进行删除操作。

查看镜像库操作步骤

1. **登录AI Stack控制台。**
2. 在顶部菜单中单击**推理服务**。
3. 在左侧菜单栏中选择**推理服务->镜像库**。
4. 查看镜像库内镜像的相关信息。

说明

支持根据镜像的RepoTags判断自定义镜像是容器镜像或应用相关镜像。标签格式：
ai.stack.application="custom"。

镜像库

镜像库展示当前已经生效的全部系统镜像和自定义镜像。如需新增自定义镜像请在操作系统中手动加载镜像。

镜像名称	Tag	Repo Tags	镜像大小	关联任务	镜像来源	镜像Hash值	创建时间
ee7e9f13a02 docker.io/library/tellm	1.3.1-pytorch	docker.io/library/tellm	38132269056	0	系统镜像	bc95a0e02814c8b0	5月 26, 2025, 14:27:45

6.4. 在线服务

6.4.1. 功能概述

功能说明

- 提供大模型在线部署能力，可选不同硬件配置、模型，支持推荐配置、自定义配置等功能；提供模型体验功能，如文本模型，可提供在线chat对话，并且支持页面选择调用模型的相关参数。
- 支持GPU虚拟化，支持显存隔离、算力隔离。

应用场景

用户拉起模型开启交互。

技术特点

通过镜像库中的容器镜像挂载模型仓库文件拉起模型，支持根据不同硬件配置进行自定义部署。提供在线chat对话并且在对话页面支持模型调用参数修改。

使用限制

需要确认容器处于运行状态，模型完全拉起。

6.4.2. 部署在线服务

本文主要介绍如何部署AI Stack在线服务。

背景信息

- 在线服务仅限管理员用户创建或删除，同时管理员可以访问所有的在线服务。
- 应用管理员可以访问所有的在线服务。
- 在线服务之间互相隔离。

前提条件

已成功登录AI Stack控制台，具体操作请参见对应文档。

操作步骤

- 以管理员[登录AI Stack控制台](#)。
- 在顶部菜单中单击[推理服务](#)。
- 在左侧菜单栏中选择[推理服务 > 在线服务](#)。
- 单击左上角的[部署服务](#)，进入在线服务配置填写界面。

i. 配置基本信息。

配置项	是否必选	说明
服务名称	是	请填写在线服务的名称，不超过256字符长度。
描述	否	在线服务的描述。

ii. 配置信息。

配置项	是否必选	说明
GPU厂商	是	目前仅支持APG、Ascend和Nvidia。  说明 具体厂商将根据多机版集群中节点所支持的GPU厂商进行展示。
节点列表	是	根据所选择的GPU厂商展示节点。
模型服务配置	是	支持高性能部署和自定义配置部署。 ■ A-Speed 高性能部署：基于阿里云AI Stack A-Speed 加速套件，提供深度优化的加速镜像，在创建流程中仅能选择支持该框架的镜像和模型。 ■ 自定义配置：可按照自身场景灵活配置部署中所需要的配置。
实例规格	否	可选，当模型服务配置选择A-Speed 高性能部署时，需要配置该参数。 ■ 极简配置（1卡，8 CPU） ■ 精简配置（2卡，48 CPU） ■ 基础配置（4卡，48 CPU） ■ 标准配置（8卡，96 CPU） ■ 专业配置（16卡，256 CPU）
模型	否	可选，当模型服务配置选择A-Speed 高性能部署时，需要配置该参数。在线服务依托的具体底层模型。

CPU数量	否	可选，当模型服务配置选择 自定义配置 时，需要配置该参数。部署在线服务时使用的CPU数量。
内存容量	否	可选，当模型服务配置选择 自定义配置 时，需要配置该参数。 部署在线服务时使用的内存容量。
资源类型	否	可选，当模型服务配置选择 自定义配置 时，需要配置该参数。 ■ GPU共享模式 ■ GPU独享 ■ CPU模式
算力配置	否	可选，当模型服务配置选择 自定义配置 且 资源类型 选择 GPU共享模式 时，需要配置该参数。 表示给本次部署的在线服务分配的算力资源，例如50%步长。
显存配置	否	可选，当模型服务配置选择 自定义配置 且 资源类型 选择 GPU共享模式 时，需要配置该参数。 表示给本次部署的在线服务分配的GPU显存，例如32GB。
GPU卡	否	可选，当模型服务配置选择 自定义配置 且 资源类型 选择 GPU共享模式 时，需要配置该参数。 请下拉选择符合本次部署的在线服务资源要求的GPU卡。
GPU数量	否	可选，当模型服务配置选择 自定义配置 且 资源类型 选择 GPU独享 时，需要配置该参数。 部署在线服务时使用的GPU数量。
共享内存容量	否	可选，当模型服务配置选择 自定义配置 时，需要配置该参数。 部署在线服务时使用的共享内存。

选择模型	是	可选，当模型服务配置选择自定义配置时，需要配置该参数。部署在线服务时使用底层模型。 ■ 系统模型：下拉选择AI Stack系统自带的模型。 ■ 自定义模型：选择自定义模型。 说明 平台无法保障自定义模型和系统镜像的兼容性，需要用户为自定义模型提供兼容性相匹配的模型框架服务镜像，以及提供对应镜像的启动命令。
选择镜像	是	可选，当模型服务配置选择自定义配置时，需要配置该参数。部署在线服务时使用的推理框架镜像。 ■ 系统镜像 ■ 自定义镜像 说明 平台无法保障系统模型和自定义镜像的兼容性，需要用户为系统模型提供兼容性相匹配的自定义模型框架服务镜像，以及提供相对应镜像的启动命令。
服务端口	否	可选，当模型服务配置选择自定义配置时，需要配置该参数。在线服务暴露的端口。
启动命令	是	可选，当模型服务配置选择自定义配置时，需要配置该参数。部署在线服务需要运行的启动命令。

iii. 高级配置。

配置项	是否必选	说明
禁用seccomp	否	勾选后，启动在线服务会增加seccomp=unconfined配置，该操作会允许当前创建的服务访问操作系统内核高危、敏感内容。
覆盖entrypoint	否	勾选后，启动服务时“启动命令”会覆盖镜像原有的entrypoint。
KVCache 加速	否	当模型服务配置是 A-Speed 高性能部署 同时模型选择Qwen3-235B时，展示本参数。 打开后启用KVCache加速功能。
KVCache 存储	否	当模型服务配置是 A-Speed 高性能部署 同时模型选择Qwen3-235B时，展示本参数。 启用时使用APFS，关闭时使用本地文件系统。
启用API Key	否	启用后会提供鉴权能力。系统会默认存储加密后的API Key，仅供模型观测服务使用。
API Key	否	请输入API Key并妥善保存。

5. 单击创建，即可拉起一个用于模型交互的在线服务。

6.4.3. 删除在线服务

本章节介绍如何删除在线服务。

背景信息

- 在线服务仅限管理员用户创建或删除，同时管理员可以访问所有的在线服务。
- 应用管理员可以访问所有的在线服务。
- 在线服务之间互相隔离。

操作步骤

1. 以应用管理员[登录AI Stack控制台](#)。
2. 在顶部菜单中单击推理服务。
3. 在左侧菜单栏中选择推理服务->在线服务。
4. 在需要删除的在线服务的操作列表，单击删除。

② 说明

等待一段时间后，即可删除用户部署的在线服务。

6.4.4. 停止在线服务

本章节介绍如何使运行中的在线服务停止。

背景信息

- 在线服务仅限管理员用户创建或删除，同时管理员可以访问所有的在线服务。
- 应用管理员可以访问所有的在线服务。
- 在线服务之间互相隔离。

前提条件

已成功登录AI Stack控制台，具体操作请参见对应文档。

操作步骤

1. 以应用管理员[登录AI Stack控制台](#)。
2. 在顶部菜单中单击[推理服务](#)。
3. 在左侧菜单栏中选择[在线服务](#)。
4. 在需要停止的在线服务的操作列表，单击[服务状态](#) > [停止](#)。

② 说明

等待一段时间后，即可停止用户部署的在线服务。

6.4.5. 启用在线服务

本章节介绍如何启用在线服务，使在线服务的状态在运行中。

背景信息

- 在线服务仅限管理员用户创建或删除，同时管理员可以访问所有的在线服务。
- 应用管理员可以访问所有的在线服务。
- 在线服务之间互相隔离。

操作步骤

1. 以应用管理员[登录AI Stack控制台](#)。
2. 在顶部菜单中单击[推理服务](#)。
3. 在左侧菜单栏中选择[在线服务](#)。
4. 在需要停止的在线服务的操作列表，单击[服务状态](#) > [启动](#)。

② 说明


等待一段时间后，即可启用用户部署的在线服务。

6.4.6. 管理在线服务

本章节介绍在线服务删除、停止、启动外的其他操作，例如查看运行日志等。

操作步骤

1. 以应用管理员[登录AI Stack控制台](#)。
2. 在顶部菜单中单击推理服务。
3. 在左侧菜单栏中选择在线服务。
 - 支持模型体验和查看运行日志。
 - 模型体验：
 - a. 单击操作列模型体验。
 - b. 可与该在线服务关联的模型进行互动。
 - c. 单击左上角 ← ，可退回至在线服务页面。
 - 查看运行日志：
 - a. 单击操作列运行日志。



- b. 支持手动刷新日志或勾选自动刷新日志。
- c. 单击下载可将全量日志下载至本地查看。

6.5. 模型观测

6.5.1. 功能概述

功能说明

用于展示Token消耗、首Token延时等信息，以了解模型的使用情况和性能变化，从而更有效地进行问题定位、故障排除和性能优化。

应用场景

需要了解模型的使用情况和性能变化，从而更有效地进行问题定位、故障排除和性能优化。

使用限制

在创建在线服务时，根据页面上是否勾选启用API Key以及是否允许观测模型使用API Key，不同的选择将导致模型观测的结果存在差异，具体情况如下表所示。

说明

模型没有启用API Key，默认就会进行观测。

是否勾选启用API Key	是否勾选允许观测模型服务使用API Key	模型观测是否支持
未勾选	未勾选	支持
已勾选	未勾选	不支持
已勾选	已勾选	支持

6.5.2. 查看模型监控数据

模型观测会展示Token消耗、首Token延时等信息，以使用户了解模型的使用情况和性能变化，从而更有效地进行问题定位、故障排除和性能优化。

操作步骤

1. [登录AI Stack控制台](#)。
2. 在顶部菜单栏中单击**推理服务**。
3. 在左侧菜单栏中选择**推理服务 > 模型观测**。

模型观测

展示Token消耗、首Token延时等信息，以了解模型的使用情况和性能变化，从而更有效地进行问题定位、故障排除和性能优化。

1小时

3小时

6小时

12小时

1天

3天

监控数据

在线服务总量 ①

2个

总调用次数

1次

总失败次数

0次

平均调用时长 ①

11.661s

平均首Token延时 ①

11.661s

在线服务列表

在线服务	模型名称	GPU卡数量/信息	调用次数	调用失败数量	成功率	平均调用时长(s)	平均首Token延时(s)	操作
5258440bqemb11	bge-reranker-v2-m3	0	0	0	100%	0	0	监控
e5873ec 集源加部-系统链接-GLM5-INT8	i9a294a... GLM5-INT8	16 0,1,2,3,4,5,6,7,8,9,10,11,12,13,1...	1	0	100%	11.661	11.661	监控

4. 单击操作列**监控**，可查看单个在线服务状态，包括周期内输出/生成token总量、周期内总token总量，首token平均延迟、输出token平均生成速率等。

7.模型体验

7.1. 功能概述

功能说明

AI Stack会预置部分文本模型和知识库，以便与大模型进行对话，从而增强检索应用的用户体验。

应用场景

主要用于与大模型进行交互，从而对客户id提供推理相关的服务。

使用限制

通过在线服务功能，创建在线服务以部署大模型。

7.2. 文本模型

本文介绍如何选择本地构建的文本模型，提供文本问答的功能。

前提条件

- 已成功登录AI Stack控制台，具体操作请参见对应文档。
- 需要确认AI Stack运行的物理节点处于正常状态。

操作步骤

1. 通过管理员账号[登录AI Stack控制台](#)。
2. 在顶部菜单中单击模型体验。
3. 在左侧菜单栏中选择模型体验 > 文本模型。
4. 在文本模型页签，单击页面右上角选择模型。
5. 选择模型后单击确定。最多支持选择三个模型。
6. 单击参数调整页签，根据下表调整模型参数。

参数名称	参数说明
stop	表示生成响应时停止生成的关键词。
max_tokens	表示单次回复最大次数。
presence_penalty	表示话题的新鲜度，可以增加话题相关性。支持填写-2~2之间的任意数。
frequency_penalty	表示减少生成时重复内容的可能性。
logit_bias	表示调节特定文字生成的概率。
user	表示发送请求的最终用户。

functions	描述要在对话中调用的函数。
function_call	定义何时及如何调用指定的函数。
temperature	表示控制生成内容的随机性。
top_p	控制生成内容随机性的核采样。

7. 确定参数后单击保存。

7.3. 视觉模型

基于AI Stack，为客户提供视觉模型体验的聊天页面功能。

前提条件

- 已成功登录AI Stack控制台。
- 已部署Qwen2.5-VL-72B-Instruct模型，可在推理服务 > 模型仓库中查看。

操作步骤

1. 通过管理员账号[登录AI Stack控制台](#)。
2. 在顶部菜单中单击模型体验。
3. 在左侧菜单栏中选择模型体验 > 视觉模型。
4. 在视觉模型页签，单击页面右上角选择模型。
5. 选择模型后单击确定。最多支持选择三个模型。
即可跟模型进行多轮对话。

调整参数

1. 在左侧菜单栏中选择模型体验 > 视觉模型。
2. 单击参数调整页签，根据下表调整模型参数。

参数名称	参数说明
stop	表示生成响应时停止生成的关键词。
presence_penalty	表示话题的新鲜度，可以增加话题相关性。支持填写-2~2之间的任意数。
frequency_penalty	表示减少生成时重复内容的可能性。
logit_bias	表示调节特定文字生成的概率。
user	表示发送请求的最终用户。

functions	描述要在对话中调用的函数。
function_call	定义何时及如何调用指定的函数。
temperature	表示控制生成内容的随机性。
top_p	控制生成内容随机性的核采样。

3. 确定参数后单击保存。

7.4. 知识库

本文介绍如何为RAG应用构建的结构化知识库，支持高效检索与生成。

说明

该操作仅支持管理员操作，应用管理员仅支持查看。

操作步骤

1. 以管理员账号[登录AI Stack控制台](#)。
2. 在顶部菜单中单击模型体验。
3. 在左侧菜单栏中选择模型体验 > 知识库。
4. 单击创建知识库。
5. 参考下表填写参数值，然后单击创建。

区域	参数名称	参数说明
基本信息	知识库名称	必填，自定义知识库名称。
	知识库描述	可选，请填写知识库其他信息。
知识库配置	Embedding模型	必填，请下载选择正确的模型。
	排序配置	必填，设定最低分数标准，只有达到或超过这个阈值的检索结果才会被考虑用于后续的排序和生成过程。
	文件上传	必填，支持上传doc, docx, pdf, txt 等类型的文件。
	文档切分chunk	必填，目前仅支持智能切分。

7.5. RAG应用体验

本文介绍如何创建应用，可基于本地知识库和大模型快速构建RAG（检索增强生成）应用，用于私域知识问答、客户支持等场景。

前提条件

已成功创建知识库，详情请参见[知识库](#)。

?

说明

该操作仅支持管理员操作，应用管理员仅支持查看。

操作步骤

- 1. 通过管理员账号[登录AI Stack控制台](#)。
- 2. 在顶部菜单中单击模型体验。
- 3. 在左侧菜单栏选择模型体验 > RAG 应用体验。
- 4. 单击创建应用。
- 5. 参考下表填写参数值，然后单击创建。

区域	参数名称		参数说明
基本信息	应用名称		必填，请自定义应用名称。
	应用描述		可选，请填写应用其他信息。
应用配置	模型选择		必填，请下拉选择正确的模型。
	API Key		必填，请填写部署在线服务时填写的API Key。
	参数配置	温度系数	表必填，示调控生成的多样性。
		最长回复长度	必填，表示模型生成的长度限制，不包含prompt。允许的最大长度因模型不同有所改变。
	知识库		必填，请根据实际情况选择相应的知识库。
	参数配置	召回片段数	必填，表示搜索召回的片段数量。数量越大，覆盖率越大，但消耗的模型input也越多。
		回复范围	必填，请设置如何判定搜索结果和用户输入的关联度。

相关操作

任务名称	操作步骤
创建API Key	1. 单击API Key管理。 2. 在页面右侧弹出页面上单击创建API Key。 3. 创建完成后，单击关闭。
删除API Key	1. 单击API Key管理。 2. 在页面右侧弹出API Key 管理页面上单击操作列删除。 3. 在弹出的提示框上单击确定。
编辑应用	1. 单击应用卡片上的编辑。 2. 修改完成后单击确定。
对话	1. 单击应用卡片上的对话。 2. 在输入框输入您的问题，单击 。 3. 等待回复即可。
调用	1. 单击应用卡片上的调用。 2. 参考请求示例的格式调用即可。
删除应用	1. 单击应用卡片上的删除。 2. 在弹出的提示框上单击确定。

8. 监控运维

8.1. 节点监控

8.1.1. 功能概述

功能说明

提供节点硬件监控信息，包括基础监控信息（CPU、内存使用率等）和各GPU卡相关监控信息，高频采集确保提供用户系统的实时运行状态并精确检测。

应用场景

用户查看节点监控数据。

技术特点

通过内核API和GPU专用接口实时抓取节点监控负载，高频采集用户系统数据并实时更新监控数据。

使用限制

需要确保节点系统时间正常。

8.1.2. 查看基础信息监控

前提条件

- 已成功登录AI Stack控制台，具体操作请参见对应文档。
- 需要确认AI Stack运行的物理节点时钟源已进行同步。

操作步骤

1. [登录AI Stack控制台](#)。
2. 在顶部菜单中单击[监控运维](#)。
3. 在左侧菜单栏选择[监控运维](#)->[节点监控](#)。
4. 查看节点的基础监控，可以选择按照不同的时间间隔查看CPU使用率、磁盘使用率、内存使用率、负载等基础信息的监控。

节点监控

展示服务器硬件相关监控信息。

基础监控 GPU监控

1小时 3小时 6小时 12小时 1天 3天

每行三个



8.1.3. 查看GPU信息监控

前提条件

- 已成功登录AI Stack控制台，具体操作请参见对应文档。
- 需要确认AI Stack运行的物理节点时钟源已进行同步。

操作步骤

1. **登录AI Stack控制台。**
2. 在顶部菜单中单击**监控运维**。
3. 在左侧菜单栏选择**监控运维->节点监控**。
4. 单击右侧**GPU监控**，可以选择按照不同的时间间隔查看节点上所有GPU卡的使用率、温度、功率等信息。

节点监控

展示服务器硬件相关监控信息。

基础监控 GPU监控

1小时 3小时 6小时 12小时 1天 3天 GPU: 全部GPU

每行三个



8.2. 告警管理

8.2.1. 功能概述

功能说明

- 告警列表：提供节点级告警管理功能，实时展示机器硬件故障告警级别和具体内容，通过Prometheus实现秒级触发，并且区分告警严重等级。支持下载全量的告警数据，已修复的告警将不再展示。
- 告警通知：通过订阅告警消息，将告警，将系统检测到的异常状态以告警的形态推送至客户告警平台，帮助客户及时、准确地响应和处理。

应用场景

用户查看节点告警数据。

技术特点

借助ipmitool，实现对服务器核心组件如CPU、风扇、主板和硬盘等的带外监控，确保设备稳定性。同时，使用smi和pcie等命令进行带内监控，检测显卡故障和温度异常，提升了对硬件资源的管理效率和故障响应速度。

使用限制

需要确保节点ipmitool/smi等命令正常。

8.2.2. 告警列表

本文介绍如何查看告警。

前提条件

- 已成功登录AI Stack控制台，具体操作请参见对应文档。
- 需要确认AI Stack运行的物理节点时钟源已进行同步。

操作步骤

1. [登录AI Stack控制台](#)。
2. 在顶部菜单中单击[监控运维](#)。
3. 在左侧菜单栏中选择[监控运维](#) > [告警管理](#) > [告警列表](#)。
4. 可以查看到节点所有告警信息的名称、告警级别、告警内容、告警发生的次数、开始时间、结束时间。
5. 单击右上角，可将全量告警数据下载至本地。
6. 单击操作列[添加事件单](#)。
7. 输入处理人和关闭原因。
8. 单击[确定](#)，即可关闭相应告警。

8.2.3. 告警通知

本章节介绍如何订阅告警并查看推送记录。

订阅告警

1. [登录AI Stack控制台](#)。

- 在顶部菜单中单击**监控运维**。
- 在左侧菜单栏中选择**监控运维 > 告警管理 > 告警通知**。
- 在**订阅**页签，单击**创建订阅**。
- 参考下表配置参数。

参数名称	参数说明
通道名称	请输入推送到告警平台的通道名称。
推送告警等级	请选择推送的告警等级，包括P1、P2、P3、P4，等级依次降低。 ◦ P1：紧急 ◦ P2：严重 ◦ P3：一般 ◦ P4：提示
推送接口URL	请输入推送到告警平台接口使用的URL。
请求头	请输入调用告警平台接口的请求头。
推送重试	表示告警平台未接收到告警后，是否按照推送策略重新推送告警消息。 默认关闭，打开后支持重试。
重试次数	当推送重试开关打开后，需要配置。 表示在重新推送告警消息时，会推送的次数。
重试间隔	当推送重试开关打开后，需要配置。 表示表示在重新推送告警消息时，每次重新推送间隔的时间，单位：分钟。
推送开关	默认关闭，打开后支持推送告警消息。

- 单击**确定**。

相关操作

订阅创建成功后，您还可以执行以下操作。

任务名称	操作步骤
------	------

测试订阅 ? 说明 当前仅支持webhook。
--

8.3. 安全规则

本文介绍如何创建、编辑、克隆、删除安全规则。

操作步骤

1. [登录AI Stack控制台](#)。
2. 在顶部菜单中单击**监控运维**。
3. 在左侧导航栏中选择**监控运维 > 安全规则**。
4. 在安全规则页面选择入方向或出方向页签。
5. 添加安全规则。
 - 添加单条安全规则。
 - a. 单击**添加安全规则**。

b. 参考下表设置参数值。

参数名称	参数说明
规则方向	分为入方向和出方向，入方向规则控制入站流量，出方向规则控制出站流量。
授权策略	在基于流量的协议、端口和授权对象匹配到某条安全组规则后，会对流量执行授权策略指定的动作，来允许或拒绝流量放行。请根据实际情况选择授权策略： ■ 允许 ■ 拒绝
协议类型	匹配流量的协议类型。请根据实际情况选择对应的协议： ■ ALL：包括以下所有的协议。 ■ TCP：传输层通信协议，建立安全连接后发送数据。 ■ UDP：传输层通信协议，无需建立安全连接，直接发送数据。 ■ ICMP：网络层协议，不传输应用数据，仅用于网络层通信管理。 ■ GRE：介于网络层和传输层之间，通常视为隧道协议。主要用于扩展网络通信能力。
端口类型	请选择源端口或目的端口。
端口范围	取值范围从1到65535；设置格式例如“1/200”、“80/80”，其中“-1/-1”不能单独设置，代表不限制端口。支持输入多个端口范围，以“,”隔开，最大不超过99。
优先级	请设置安全规则优先级。取值范围：1~100 默认值：1。数值越小代表优先级越高。
IP协议	负责在网络中定位设备并传输数据包的通信协议，支持IPv4或IPv6。
授权对象	■ 入方向规则中匹配流量的源地址，出方向规则中匹配流量的目的地址。 ■ 请输入授权对象，格式为：10.x.y.z/32，如果有多组，请用','隔开，最多支持添加十组授权对象。
描述	请输入安全规则的其他信息，长度为 1~512 个字符，不能以 http:// 和 https:// 开头。

c. 单击确定。

o. 添加多条安全规则。

a. 单击批量添加安全规则。

- b. 在弹框上单击规则模板，下载模板文件至本地。



- c. 在本地打开模板文件，参考上述步骤的参数说明填写后保存。
- d. 在弹框上单击上传文件，选择本地填好的文件单击打开。
- e. 单击确定。
- f. 在弹框确认导入的安全规则是否正确，确认后单击确定。

相关操作

创建安全规则后，您还可以执行以下操作。

任务名称	操作步骤
修改安全规则	1. 单击操作列修改。 2. 修改完成后单击确定。
克隆安全规则	1. 单击操作列克隆。 2. 确认克隆参数无误后单击确定。
删除安全规则	1. 单击操作列删除。 2. 在弹出提示框上单击确定。

8.4. 网络监控运维

该功能仅在多机版AI Stack支持，单机版不支持。

8.4.1. CPN监控

AI Stack多机版支持监控CPN的主机和交换机指标数据，本章节介绍如何查看指标数据。

操作步骤

1. 登录AI Stack控制台。
2. 在左上角单击**单机版**，选择**多机版**切换为多机版页面。
3. 在顶部菜单栏中单击**监控运维**。
4. 在左侧导航栏中选择**网络监控运维 > CPN监控**。
即可查看主机监控大盘和交换机监控大盘下的指标数据。

8.4.2. CPN告警

AI Stack多机版支持查看CPN的主机和交换机告警数据，本章节介绍如何查看告警数据。

操作步骤

1. [登录AI Stack控制台](#)。
2. 在左上角单击 **单机版**，选择**多机版**切换为多机版页面。
3. 在顶部菜单栏中单击**监控运维**。
4. 在左侧导航栏中选择**网络监控运维 > CPN告警**。
即可查看主机告警和交换机告警，包括告警时间、告警等级、告警详情、告警来源等内容。

8.4.3. SYSLOG日志

本章节介绍如何查看syslog（System Logging Protocol）日志消息。

操作步骤

1. [登录AI Stack控制台](#)。
2. 在左上角单击 **单机版**，选择**多机版**切换为多机版页面。
3. 在顶部菜单栏中单击**监控运维**。
4. 在左侧导航栏中选择**网络监控运维 > SYSLOG日志**。
5. 选择交换机并设置时间范围，即可查看符合条件的日志信息。

9.应用中心

9.1. 应用商店

应用商店展示所有入驻到应用商店的AI应用，支持应用检索，应用部署等，本文介绍应用商店相关具体内容。

界面入口

1. 登录AI Stack控制台，在顶部导航栏，单击**应用中心**。
2. 在左侧导航栏，单击**应用商店**，进入应用商店页面。

应用查询

1. 在应用商店页面，可以查看到所有入驻到应用商店的AI应用。支持按照**上架时间**、**价格**排序。



2. 在服务商下拉列表中选择服务商，搜索框中输入**服务商/服务ID/应用名称**，可以根据筛选条件查询相关应用，支持按照**应用类型**查询应用。



导入应用

导入应用

1. 在应用商店页面，单击**导入应用**。
2. 在弹出的导入应用弹框中，单击**选择文件并上传**，上传云上产品应用基线zip包文件，单击**确定**。应用导入完成后，即可在应用商店查看该应用，并选择**试用**或**正式部署**应用。



一键导入

说明

部署应用过程中，选择应用系统版本时，如果没有可选的已有版本，可使用一键导入快捷完成版本导入。

1. 在应用部署的基础配置页面，单击应用系统版本下拉列表中的一键导入。



2. 根据弹出的一键导入弹框步骤，开始一键导入操作。

- i. 访问[飞天企业版在线管理平台](#)的软件中心，根据云实例下载制品到本地。
- ii. 将制品文件上传至AIStack一体机。
- iii. 输入AIStack一体机中制品文件绝对路径，单击**生成命令**，有效期2小时。
- iv. 单击**复制命令**，进入AIStack一体机执行复制的命令，最终提示success表示执行成功。

一键导入

✕

- 1、访问飞天企业版在线管理平台的软件中心，根据云实例下载制品到本地

<https://asonline.console.aliyun.com/software> 

- 2、将制品文件上传至AIStack一体机

- 3、输入AIStack一体机中制品文件绝对路径，点击“生成命令”，有效期2小时

生成命令

生成命令结果

 复制命令

- 4、进入AIStack一体机执行命令，最终提示 success 表示执行成功

取消

应用详情

1. 在应用商店页面，单击目标应用卡片，进入应用详情页面。
2. 在应用详情页面，可以查看应用的交付方式、版本、分类、服务商信息、应用介绍、购买介绍和使用指南等信息。

说明

应用详情的具体信息以开发者中心维护上架的为准。

部署应用

1. 在应用详情页面，单击开始部署。
2. 在弹出的提示框中，单击我已知晓，下一步，进入部署页面，开始进行部署操作。

i. 基础配置

在基础配置中，填写相关参数，完成基础配置后，单击下一步，进入依赖检查。

应用商店 / 应用详情 / 应用部署

← 应用名称: DataV可视化智能应用

1 基础配置

2 依赖检查

3 资源配置

4 应用设置

5 信息确认

6 完成

应用系统基础信息

部署实例名称

test001

7/64

长度不超过64个字符，必须以英文字母开头，可包含数字、英文字母、短划线 (-) 和下划线 (_)。

服务实例描述

test001

7/256

长度为2-256个字符，不能以http://或https://开头，支持中英文、数字、全角字符及"_"、"-","."半角字符。

应用系统版本

1.2

6)

制品状态

制品已完成

应用系统规格

Standard

前置检查

前置检查通过

取消

下一步

相关参数说明：

字段名称	是否必填	字段说明
部署实例名称	是	- 用于给部署实例其别名用于区分。 - 长度不超过64个字符，必须以英文字母开头，可包含数字、英文字母、短划线 (-) 和下划线 (_)。
服务实例描述	是	- 用于对服务实例的描述。 - 长度为2-256个字符，不能以http://或https://开头，支持中英文、数字、全角字符及"_"、"-","."半角字符。
应用系统版本	是	- 选择已有的版本号。 ? 说明 版本号括号中显示的是CICD构建任务ID。 - 一键导入：当没有可选的已有版本时，快捷进行版本导入。
制品状态	是	- 选择应用系统版本后会联动显示该字段，只读，展示制品状态。 - 未完成制品导入的应用，无法部署。
应用系统规格	是	不同规格对应着不同的基线文件。
前置检查	是	- 选择应用系统规格后会联动显示该字段，只读。 - 前置检查通过后，才能进入下一步。

ii. 依赖检查

在依赖检查中，有依赖时，所有检查项通过后，允许进入下一步。未通过的检查项，根据列表中状态列的信息，单击去部署，进行相关依赖的部署。



检查通过，无任何依赖

说明

- 云产品依赖的情况，单击去部署，直接跳转到该应用的详情页。
- 非商用技术组件未部署的情况，单击去部署，直接跳转到非商用组件的详情页。

iii. 资源配置

在资源配置中，填写相关参数，完成资源配置后，单击下一步，进入应用设置。

应用商店 / 应用详情 / 应用部署

← 应用名称: Dc

基础配置

依赖检查

3 资源配置

4 应用设置

5 信息确认

6 完成

部署节点配置

部署节点

localhost

容器集群配置

容器集群

default

上一步

下一步

相关参数说明：

字段名称	是否必填	字段说明
部署节点	是	- 目前无法修改。 - AI Stack多机版后可以修改，可以选择部署到其他机器节点。
容器集群	是	- 数据源来自容器集群管理。 - 取决于应用是单机部署，还是集群部署的，如果应用是基于K8s拉起，则需要选择对应的容器集群。

iv. 应用设置

在应用设置中，填写相关参数，完成应用设置后，单击下一步，进入信息确认。

应用商店 / 应用详情 / 应用部署

← 应用名称: []

✓ 基础配置

✓ 依赖检查

✓ 资源配置

4 应用设置

5 信息确认

6 完成

应用配置

HO

1

✕

M

✕

M

1

✕

M

te

✕

MP

✕

RE

1

✕

R

✕

R

te

✕

PL

....

✕

PI

1

✕

P

te

✕

P

1

✕

上一步

下一步

v. 信息确认

在信息确认中，进行信息的确认。

应用商店 / 应用详情 / 应用部署

← 应用名称: []

✓ 基础配置

✓ 依赖检查

✓ 资源配置

✓ 应用设置

5 信息确认

6 完成

基础配置

服务实例名称

te

服务实例描述

te

应用系统版本

1

制品状态

制品已完成

应用系统规格

Standard

前置检查

前置检查通过

资源配置

部署节点

localhost

容器集群

default

应用配置

HOS

E

MYS

te

My

IT

MYS

te

MYS

te

REDIS

ST

RED

te

RED

te

PC

PG_HOST

te

PG_PORT

te

PC

PG_PASSWORD

te

VLLM_BASE

te

VLLM_N

te

modi

Defa...

1

上一步

开始执行

vi. 完成

单击开始执行，生成部署任务。

部署进度

- 1. 在应用详情页面，单击部署进度。
- 2. 在部署进度列表中，可查看所有相关部署任务。

部署进度						×
部署实例名称	版本	规格	部署开始时间	部署结束时间	工单状态	
test001	1.0.0	Standard	2025年06月30...	2025年06月30...	执行中	
共 1 项						< 1/1 >

3. 单击部署实例名称列的实例名称，可快速跳转到已部署实例的详情页面。

9.2. 我的应用

我的应用展示已经部署的应用实例，支持模糊搜索和查看应用详情，本文介绍我的应用具体内容。

界面入口


1. 登录AI Stack控制台，在顶部导航栏，单击应用中心。
2. 在左侧导航栏，单击我的应用，进入我的应用页面。

应用查询

1. 在我的应用页面，可以查看到所有已经部署的应用实例。



2. 在搜索框中输入部署实例名称关键词，可以模糊搜索相关应用的部署实例。



应用详情

1. 在**我的应用**页面，单击目标应用卡片，进入应用详情页面。
2. 在应用详情页面，可以查看访问入口、基本信息、应用组件、部署日志等。其中，基本信息显示的修订号内容为CI/CD构建任务ID，便于支持客户现场问题时，查询到对应的版本和代码。

← AI		theus	应用升级		应用下线		
prom 阿里云计算有限公司 prom 概述							
基本信息							
更新时间	2026-01-27 13:51:00	类别	AI平台软件/中间件	版本	1.5.0		
修订号	5a465	规格	5	供应商	阿里云计算有限公司		
售前支持	阿里云计算有限公司						
访问入口							
入口名称	入口说明		入口地址				
ack-pr	er(62981)	Web服务入口	http	81			
ack-pr	er(57526)	Web服务入口	http	26			
ack-pr	j(62980)	Web服务入口	http	80			
应用组件							
组件名称	组件类型	命名空间	修订号	组件状态	创建时间		
ack-operator-14b429...	HelmChart		2	deployed	2026-01-27 13:51:41		
crds	HelmChart		2	deployed	2026-01-27 13:51:02		
kub-	HelmChart		2	deployed	2026-01-27 13:51:40		
mysql	HelmChart		2	deployed	2026-01-27 13:51:02		

部署日志

Pr

act:

pr

20

Uj

crds

Uj

pr

20

porter

Uj

mysql

Uj

pr

20

ack-

Uj

pr

20

pu-

Uj

pr

ex

20

Uj

pr

ex

20

Uj

st

20

Uj

pr

20

teaway

② 说明

访问入口，目前支持显示HTTP、HTTPS（PaaS Portal）和TCP（Kafka）协议类型。

应用下线

在应用详情页面，单击应用下线，在弹出的对话框中单击确定，可以下线应用。



应用升级

前提条件

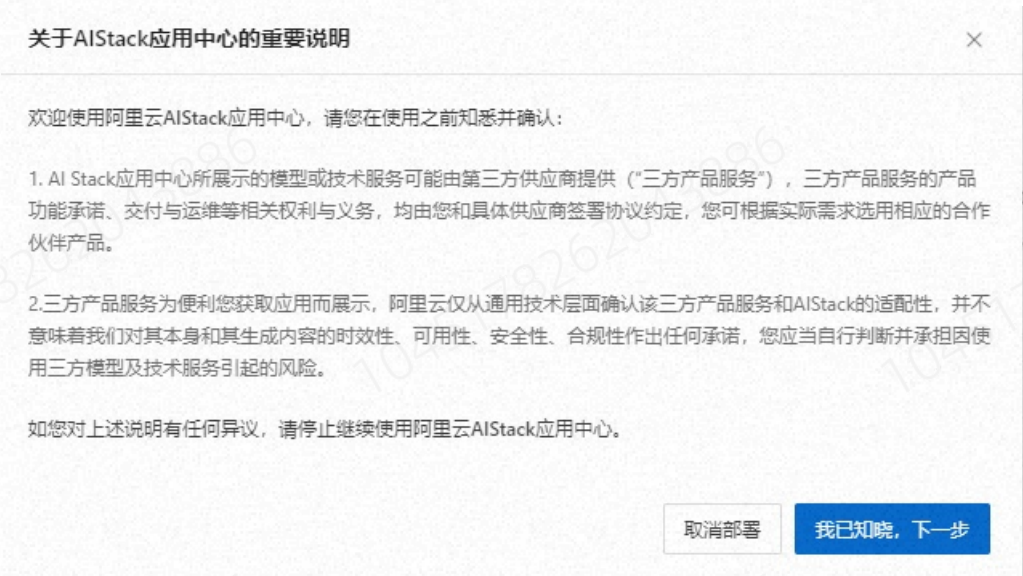
当应用的Release和工作负载处于终态时，应用允许升级。

操作步骤

1. 在**我的应用**页面，单击目标应用卡片，进入**应用详情**页面。
2. 在**应用详情**页面，单击**应用升级**。



在重要说明弹框单击我已知晓，下一步。



3. 进入升级流程，完成以下4个步骤。

i. 基础配置。

← 应用名称: prom

1 基础配置

2 依赖检查

3 资源&应用配置

4 完成

基础配置

实例名称 *

prom4/64

长度不超过64个字符，必须以英文字母开头，可包含数字、英文字母、短划线 (-) 和下划线 (_)

实例描述 *

prom测试7/256

长度为2-256个字符，不能以http://或https://开头，支持中英文、数字、全角字符及"'"`~半角字符

版本

当前版本: 1.5.0

升级版本: 选择新版本

规格 *

Standard

选择要升级的版本，其他参数不可编辑，单击下一步进入依赖检查。

④ 说明

只能从低版本升级到高版本，当没有升级的版本制品文件时，可一键导入制品包。

ii. 依赖检查。

展示新的产品依赖，如果新的产品依赖未部署，需先进行部署，然后单击下一步，进入资源配置。

iii. 资源配置&应用配置。

a. 资源配置

资源配置

部署节点

localhost

命名空间

arms-prom

容器集群

default

部署节点配置及容器集群配置参数不可编辑。

b. 应用设置。

应用设置

已有配置

CLUSTER_SCALE

4

HIGH_AVAILABILITY

statefulset

MYSQL_HOST

MYSQL_PORT

MYSQL_USER

MYSQL_PASSWORD

MYSQL_DATABASE

- 在新增配置模块，填写升级前版本中不存在的配置。
- 在已有配置模块，如果升级前版本中存在的同名值，允许修改。
- 在删除配置模块，暂时待删除的配置，不允许编辑。

c. Chart变化。

chart 变化

更新的Chart

名称

prometheus-k8s-xpu-exporter

名称

kube-state-metrics

名称

crds

名称

prometheus-push-gateway

名称

prometheus-npu-exporter

名称

prometheus-node-exporter

名称

prometheus-gpu-exporter

名称

prometheus-dcu-exporter

名称

mysql

名称

ack-prometheus-operator

名称

prometheus-mvda-gpu-exporter

页面展示新增的**Chart**、更新的**Chart**、删除的**Chart**，其中删除的chart需要输入chart名称进行确认，单击预览配置，查看升级配置信息。

iv. 完成。

MYSQL_USER ①

MYSQL_PASSWORD ①

🔒

MYSQL_DATABASE ①

chart 变化

更新的Chart

名称

prometheus-k8s-xpu-exporter

kube-state-metrics

crds

prometheus-push-gateway

prometheus-npu-exporter

prometheus-node-exporter

prometheus-gpu-exporter

prometheus-dcu-exporter

mysql

ack-prometheus-operator

prometheus-nvidia-gpu-exporter

🔍 预览配置

上一步

开始执行

针对本次升级的详细信息，确认无误后，单击开始执行。

← 返回

成功

完成

基础配置

依赖检查

资源与应用配置

完成

已成功提交工单

查看工单 (0)

返回上级页面

可单击查看工单查看升级流程或返回上级页面。

9.3. 容器集群管理

容器集群管理仅对已注册的容器集群进行展示，本文介绍容器集群管理的具体内容。

界面入口

- 1. 登录AI Stack控制台，在顶部导航栏，单击应用中心。
- 2. 在左侧导航栏，单击容器集群管理，进入容器集群管理页面。

容器集群查询

- 1. 在容器集群管理页面，可以查看到所有已注册的容器集群。

容器集群管理

🔍 支持关键词模糊搜索

最近同步时间：2023/10/31

集群来源	集群类型	集群名称	描述
ACK	Kubernetes	2- - - <	2- - - - -

共 1 项 < 1/1 >

- 2. 在搜索框中输入关键词，可以模糊搜索相关集群。

9.4. 授权信息

当现场节点资源不足时，可以通过导入授权增加资源，同时可查看专有云产品授权规格基本信息。

导入授权

1. 登录AI Stack控制台，在顶部导航栏，单击应用中心。
2. 在左侧导航栏，单击授权信息，进入授权信息页面。
3. 单击导入授权，上传授权文件。

说明

仅支持.tar类型的文件。

4. 单击确定。

查看授权信息详情

在授权信息页面，查看环境中的授权基本信息，各项授权信息说明如下：

基本信息						导入授权
授权版本	Lice	授权状态	效中	客户ID	100	
云实例ID	cl	客户UID		云平台版本	AS4	
客户名称	刘	授权创建时间	24日			

授权信息	描述
授权版本	展示详细版本号，其中： • TRIAL表示当前是试用授权，试用授权的有效期为从部署起的90天内。 • FORMAL表示当前是正式授权，其产品授权信息来源于合同签署的内容。
授权状态	表示当前的授权类型和授权状态。 • 授权类型包括以下两种： ◦ 试用授权 ◦ 正式授权 • 授权状态包括以下五种： ◦ 未激活 ◦ 即将过期 ◦ 生效中 ◦ 已过期 ◦ 过期/超量
客户ID	一般客户的唯一标识。
云实例ID	现场环境对应规划系统上的云实例ID。
客户UID	会员客户的唯一标识。

云平台版本	表示当前云平台的商用版本。
客户名称	购买专有云产品的客户名称。
授权创建时间	表示授权开始的时间。

产品授权

在授权信息页面，查看各产品授权信息，具体的授权规格信息说明如下表所示。

产品授权							
Q 支持产品名称模糊搜索							
序号	商品名称	商品规格	授权模式	授权数量	软件许可更新和技术支持有效时间	授权状态	
1	标...	未收入...	授权模式		2025年11月24日 - 2026年11月24日	生效中	
2	专...模型	...	授权模式		2025年11月24日 - 2026年11月24日	生效中	

列表项	描述
商品名称	云产品名称。
商品规格	云产品规格名称。
授权模式	云产品授权模式： - 授权模式 - 订阅模式 - 临时附加模式
授权数量	云产品购买的授权数量。
软件许可更新和技术支持有效时间	项目有效期。
授权状态	云产品授权规格当前的授权状态。 - 生效中 - RENEW服务已过期 - 产品规格已超量

10.节点管理

10.1. 功能概述

功能说明

展示当前节点基本信息，可提供远程登录、密码修改、主机名修改等功能，节点管理功能通过执行定制化脚本，目前支持将GPU实例作为节点添加到集群。

应用场景

用户查看节点数据或进行相关节点管理操作。

技术特点

通过执行定制化脚本实现密码和主机名修改操作，通过自研WebConsole服务实现节点远程登录操作。

使用限制

需要确保运行节点处于正常状态。

10.2. 远程登录

前提条件

- 已成功登录AI Stack控制台，具体操作请参见对应文档。
- 需要确认AI Stack运行的物理节点处于正常状态。

操作步骤

1. [登录AI Stack控制台](#)。
2. 在顶部菜单栏单击资源管理。
默认进入节点管理页面。
3. 可以查看到节点名称、主机名、节点状态、配置、IP地址等信息。
4. 单击操作列表中的远程登录。
5. 在远程登录的表单中填写登录到机器节点的用户名。
6. 单击确认，跳转到WebConsole界面。
7. 在WebConsole界面输入用户名对应的密码，按回车键即可远程登录机器节点终端进行操作。

10.3. 修改root用户密码

前提条件

- 已成功登录AI Stack控制台，具体操作请参见对应文档。
- AI Stack运行的物理节点处于正常状态。
- 当前登录用户具有管理员权限。

操作步骤

1. [登录AI Stack控制台](#)。
2. 在顶部菜单栏，单击资源管理。
默认进入节点管理页面。

3. 可以查看到节点名称、主机名、节点状态、配置、IP地址等信息。
4. 单击操作列的修改密码。
5. 在修改密码的界面中填写新密码和确认密码。
6. 单击确认，节点root账户的密码即可修改成功。

10.4. 修改主机名

前提条件

- 已成功登录AI Stack控制台，具体操作请参见对应文档。
- AI Stack运行的物理节点处于正常状态。
- 当前登录用户具有管理员权限。

操作步骤

1. 登录AI Stack控制台。
2. 在顶部菜单栏单击资源管理。
默认进入节点管理页面。
3. 可以查看到节点名称、主机名、节点状态、配置、IP地址等信息。
4. 单击操作列表中的修改主机名。
5. 在修改主机名的表单中填写需要修改的主机名。
6. 单击确认，即可修改节点主机名称。

11. 系统管理

11.1. 用户管理

11.1.1. 功能概述

功能说明

提供用户管理功能，整体用户设计包括管理员、安全管理员、应用管理员和审计管理员。

- 管理员：
 - 系统预置，一台AI Stack只有一个管理员。
 - 具有远程登录、提交镜像、部署在线服务、创建/管理用户（创建安全管理员，创建审计管理员）的权限。
 - 支持配置管理员本身及其他账户的MFA认证。
- 安全管理员：
 - 具有禁用管理员的权限，禁用后管理员账号无法登录。
 - 具有创建/管理用户的权限。
 - 一台AI Stack只有一个安全管理员。
 - 一经创建无法删除。
 - 支持配置管理员（admin）的MFA认证。
- 应用管理员（使用者）：
 - 具有查看静态数据（模型列表，镜像列表），查看以及使用运行中的服务（模型体验），修改自身密码的权限。
- 审计管理员：
 - 具有审计日志的权限。
 - 一台AI Stack只有一个审计管理员。
 - 一旦创建，无法删除。

应用场景

用户注册、登录等用户相关操作。

技术特点

实现多级RBAC权限体系，明确区分管理员、安全管理员、应用管理员和审计管理员的权限，并确保数据可见性隔离，同时支持密码强度策略等安全特性。

使用限制

首次登录时，管理员用户会被强制要求修改密码。

11.1.2. 创建用户

前提条件

- 已成功登录AI Stack控制台，具体操作请参见对应文档。
- 需要确认AI Stack运行的物理节点处于正常状态。

- 当前登录用户具有管理员/安全管理员权限。

操作步骤

1. 管理员账户[登录AI Stack控制台](#)。
2. 在顶部菜单中单击系统管理。
3. 在左侧菜单栏选择系统管理 > 用户管理。
4. 可以查看到目前AI Stack可登录的用户信息。
5. 单击左上角的创建用户按钮。
6. 在创建用户的表单中填写。

配置项	是否必填	说明
用户名	是	创建的用户名称，由字母、数字、下划线（_）、半角句号（.）、短划线（-）、或“@”符号组成，长度为 2~64 个字符。
显示名	是	显示名称，可由字母、数字、中文、半角句号（.）、短划线（-）、空格符及“@”符号组成，长度为 1~128 个字符。
角色	是	根据实际需求选择。 ◦ 安全管理员 ? 说明 安全管理员创建后不支持删除。 ◦ 审计管理员 ◦ 应用管理员
邮箱	否	填写对应的邮箱。
手机	否	填写对应的手机号。
密码	是	用户登录使用的密码。
确认密码	是	重新输入用户登录使用的密码。

7. 单击确定，即可创建出对应信息的用户。
首次以该用户登录时请按照界面提示修改密码。

11.1.3. 管理MFA

11.1.3.1. MFA概述

MFA (Multi-Factor Authentication)，多因子认证，是计算机系统中一种进行身份认证的方法，您需要通过两种或两种以上认证手段的校验才能进入系统，访问资源。本文将为您介绍MFA认证的原理和使用场景。

MFA介绍

启用MFA后，当您登录AI Stack控制台时，系统将要求输入用户名和密码（第一安全要素），然后要求输入来自其MFA设备的动态验证码（第二安全要素），双因素的安全认证将为您提供更高的安全保护。

MFA设备遵循TOTP (Time-Based One-Time Password) 算法，能够基于时间产生6位数字的动态验证码。AI Stack控制台支持基于软件的虚拟MFA设备。您可以在移动设备（如智能手机）上安装支持虚拟MFA的软件（如阿里云APP），以此来作为虚拟MFA设备。

使用限制

目前采用的基于时间序列的TOTP算法，使用时要求专有云服务的系统时钟要和公网的标准时间保持一致，否则可能存在由于时间不同步，导致MFA码不一致，无法登录的情况。

11.1.3.2. 开启并绑定虚拟MFA设备

本章节介绍在创建新用户并开启MFA设备后，如何绑定MFA设备。

前提条件

- 已创建新用户并已开启MFA设备配置功能。
- 获取MFA安全码。
 - i. 在手机上下载具有虚拟MFA功能的应用程序，推荐使用阿里云APP。
 - ii. 下载后打开程序，扫描下面二维码，添加账号后获取6位数虚拟动态码。
 - iii. 重新登录，在有效时间内输入6位虚拟动态码，完成认证。

⚠ 重要

该页面的二维码、密钥只会生产一次，若想分享或绑定多设备，请及时保存。

操作步骤

1. 以管理员登录AI Stack控制台。
2. 在顶部菜单中单击**系统管理**。
3. 在左侧菜单栏选择**系统管理 > 用户管理**。
4. 在**用户管理**页面单击对应用户操作列... > **开启MFA**。



5. 以新用户登录AI Stack控制台。
6. 根据界面提示修改新用户的登录密码。

7. 修改成功后以新密码再次登录AI Stack控制台。
8. 按照界面提示获取安全码并输入后，单击确定绑定。



9. 输入6位动态码，单击认证即可登录成功。




0. 后续以该用户登录AI Stack控制台时，需要先输入用户名和密码，勾选产品使用条款后，单击登录。
1. 输入来自其MFA设备的6位动态验证码，单击认证。认证成功后即可登录成功。

11.1.3.3. 关闭并解绑虚拟MFA设备


关闭MFA认证，您需要解绑MFA设备。本文为您介绍如何解绑并停用虚拟MFA设备。

操作步骤

1. 以管理员登录AI Stack控制台。
2. 在顶部菜单中单击系统管理。
3. 在左侧菜单栏选择系统管理 > 用户管理。
4. 在用户管理页面单击对应用户操作列... > 关闭MFA。
5. 单击确定，即可为用户关闭MFA多因素认证功能。



6. 在对应用户操作列单击... >解绑MFA。



7. 在弹出的提示框上单击确定。

关闭MFA功能之后，下次登录时您只需要输入用户名和密码即可。

说明

如果管理员admin需要关闭并解绑MFA设备，请使用安全管理员登录AI Stack控制台，参考上述步骤关闭并解绑虚拟MFA设备。

11.1.4. 编辑用户

前提条件

- 已成功登录AI Stack控制台，具体操作请参见对应文档。
- 需要确认AI Stack运行的物理节点处于正常状态。
- 当前登录用户具有管理员/安全管理员权限。

操作步骤

1. 通过管理员账号[登录AI Stack控制台](#)。
2. 在顶部菜单中单击**系统管理**。
3. 在左侧菜单栏选择**系统管理 > 用户管理**。
4. 可以查看到目前AI Stack可登录的用户信息。
5. 在需要编辑信息的用户后操作列表点击**编辑**按钮。
6. 在编辑用户信息的表单中填写。

配置项	是否必填	说明
显示名	是	显示名称，可由字母、数字、中文、半角句号 (.)、短划线 (-)、空格符及 “@” 符号组成，长度为 1~128 个字符。
邮箱	否	填写对应的邮箱。
手机	否	填写对应的手机号。

7. 单击**确认**，即可创建出对应信息的用户。

11.1.5. 禁用用户

前提条件

- 已成功登录AI Stack控制台，具体操作请参见对应文档。
- 需要确认AI Stack运行的物理节点处于正常状态。
- 当前登录用户具有管理员权限。
- 安全管理员权限可以禁用管理员账号。

使用限制

禁用操作对当前登录用户不予生效。

禁用用户操作步骤

1. 通过管理员账号[登录AI Stack控制台](#)。
2. 在顶部菜单中单击系统管理。
3. 在左侧菜单栏选择系统管理 > 用户管理。
4. 可以查看到目前AI Stack可登录的用户信息。
5. 在需禁用的用户后操作列表点击禁用按钮，即可禁用该用户，禁用后此用户无法通过账号密码形式登录到AI Stack控制台。

11.1.6. 删除用户

前提条件

- 已成功登录AI Stack控制台，具体操作请参见对应文档。
- 需要确认AI Stack运行的物理节点处于正常状态。
- 当前登录用户具有管理员/安全管理员权限。

使用限制

删除操作对当前登录用户不予生效。

操作步骤

1. 通过管理员账号[登录AI Stack控制台](#)。
2. 在顶部菜单中单击系统管理。
3. 在左侧菜单栏单击系统管理 > 用户管理。
4. 可以查看到目前AI Stack可登录的用户信息。
5. 在需禁用的用户后操作列表点击...按钮，在出现的下拉框中单击删除按钮。
6. 单击确认按钮，即可删除所选择的用户。

11.1.7. 重置用户密码

本章节介绍修改密码时的步骤和注意事项。

背景信息

- 新密码不得与最近五次使用的密码相同。
- 密码过期时间为90天，当前不支持修改该过期时间。
- 每次修改密码后，系统将重新计算密码有效期限，若超过90天，用户在登录时将被强制要求修改密码。

前提条件

- 已成功登录AI Stack控制台，具体操作请参见对应文档。
- 需要确认AI Stack运行的物理节点处于正常状态。
- 当前登录用户具有管理员/安全管理员权限。

使用限制

不支持管理员用户重置自身的密码。

操作步骤

1. 通过管理员账号[登录AI Stack控制台](#)。
2. 在顶部菜单中单击**系统管理**。
3. 在左侧菜单栏选择**系统管理 > 用户管理**，查看目前AI Stack可登录的用户信息。
4. 在需重置密码的用户操作列表单击...按钮，在出现的下拉框中选择**重置密码**。
5. 在重置密码的下拉框中填写重置的密码和确认密码，单击**确定**，重置操作即刻生效。

11.1.8. 用户角色授权

前提条件

- 已成功登录AI Stack控制台，具体操作请参见对应文档。
- 需要确认AI Stack运行的物理节点处于正常状态。
- 当前登录用户具有管理员/安全管理员权限。
- 角色授权调整后需要保证AI Stack用户列表中至少存在一位管理员用户。

使用限制

不支持管理员用户对自身进行角色授权操作。

操作步骤

1. 通过管理员账号[登录AI Stack控制台](#)。
2. 在顶部菜单中单击**系统管理**。
3. 在左侧菜单栏选择**系统管理 > 用户管理**。
4. 可以查看到目前AI Stack可登录的用户信息。
5. 在需要角色授权的用户操作列表单击**角色授权**按钮。
6. 在角色授权表单的角色下拉框处选择为该角色授权的身份，单击**确定**按钮，该用户角色即刻生效。

11.2. 操作日志

本文介绍如何查看在AI Stack控制台上面的操作日志详情。

前提条件

- 已成功登录AI Stack控制台，具体操作请参见对应文档。
- 需要确认AI Stack运行的物理节点处于正常状态。
- 当前登录用户具有管理员/审计管理员权限。

操作步骤

1. 通过管理员账号[登录AI Stack控制台](#)。

2. 在顶部菜单中单击**系统管理**。
3. 在左侧菜单栏选择**系统管理 > 操作日志**。
4. 单击**操作列操作详情**，可以查看到目前AI Stack上面操作的日志信息；包括操作人用户名、事件、操作人角色、操作所在节点和操作完成时间等信息。

说明

日志信息最长可保存180天。

11.3. 授权管理

为当前AI Stack提供授权管理能力。

前提条件

请提前获取（临时/正式）授权码，如果已经导入过临时授权码，请获取正式授权码。

操作步骤

1. 通过管理员账号[登录AI Stack控制台](#)。
2. 在顶部菜单中单击**系统管理**。
3. 在左侧菜单栏选择**系统管理 > 授权管理**。
4. 单击**授权导入**。
5. 输入授权码后单击**确定**。

说明

- 支持导入临时授权码，单个节点仅允许使用一次临时授权（90天），后续使用需要购买正式授权码。
- 临时授权码只允许导入一次。
- 临时授权在使用过程中，导入授权功能仅支持导入正式授权码。

11.4. SP管理

本章节介绍如何接入IDP，使应用接入SSO管理。

前提条件

已获取SP元文件配置，元文件格式请参见[示例文件](#)。

操作步骤

1. 以管理员账号[登录AI Stack控制台](#)。
2. 在顶部菜单中单击**系统管理**。
3. 在左侧菜单栏选择**系统管理 > SP管理**。
4. 单击**接入SP**。
5. 输入服务名称，在接入配置输入框中输入SP元文件配置。
6. 单击**确定**。

其他操作

成功接入SP后，您还可以执行以下操作。

任务名称	操作步骤
查询SP	支持以服务名称或EntityID维度查询。
查看SP详情	单击操作列详情。
修改SP	1. 单击操作列修改。 2. 配置修改完后单击确定。
删除SP	1. 单击操作列删除。 2. 在弹出的提示框上单击确定。
下载IDP元数据	1. 单击IDP元数据下载。 2. 复制内容至本地即可。

示例文件

JSON

```
{
  "@class" : "org.apereo.cas.support.saml.services.SamlRegisteredService",
  "serviceId" : "entityID",
  "name" : "服务名称",
  "id" : SP的整数ID,
  "attributeReleasePolicy": {
    "@class": "org.apereo.cas.services.ReturnAllAttributeReleasePolicy"
  },
  "accessStrategy": {
    "@class": "org.apereo.cas.services.DefaultRegisteredServiceAccessStrategy",
    "enabled": true,
    "ssoEnabled": true
  },
  "evaluationOrder" : 10,
  "metadataLocation" : "SP元文件路径",
  "signAssertions":true
}
```

11.5. 系统设置

11.5.1. 系统版本

本章节介绍如何在AI Stack环境中直接升级。

前提条件

- 请提前在阿里云CICD获取升级压缩软件包，压缩包格式为.7z；请不要自行组包，破坏升级包结构。
- 请提前上传升级压缩包至操作系统/bmcp_lvm_fs/cusa/upgrade/路径下；请勿自行解压升级压缩包，由系统统一解压。

操作步骤

1. 以管理员账号[登录AI Stack控制台](#)。
2. 在顶部菜单中单击系统管理。
3. 在左侧菜单栏选择系统管理 > 系统设置。
4. 系统会显示当前版本，单击本地升级。
5. 单击操作列解压，解压成功后单击升级。

本地升级

软件压缩包请放置在操作系统/bmcp_lvm_fs/cusa/upgrade/路径下;请勿自行解压软件压缩包。

识别到如下软件压缩包

软件压缩包	版本名称	解压状态	操作
bbb_AIStack-v025-07-31-11-32-48-md5-eb565dc5d008eafbc1285d9606ab2b57.7z	ik66ce7m_2v2.5.0	未解压	解压 升级
export_package_cfn5e_2025-08-06-14-30-36-md5-9b78e19ddc13bc.7z	-	检查成功	解压 升级
release_AIStackm_2025-07-31-11-32-48-md5-9b78e19ddc13bc.7z	hk66ce7m_2v2.5.0	检查成功	解压 升级
test-AIStack-	v2.6.0	未解压	解压 升级

关闭

查看升级任务列表

6. 在弹出的提示框上单击确定。升级任务会加入升级任务列表中执行升级，在此页面停留2-3s后会自动跳转到升级任务详情。

确定升级到v2.5.0版本吗?

升级期间平台功能和RAG服务不可用，请确保在不影响您的业务前提下进行升级。

取消

确定

7. (可选) 关闭升级任务页面后，需要再次查看升级任务时，请单击查看升级任务列表 查看所有升级任务。

11.5.2. 自定义配置

AI Stack支持用户自定义平台名称、平台Logo以及浏览器显示名称和显示图标。

操作步骤

1. 以管理员账号[登录AI Stack控制台](#)。
2. 在顶部菜单中单击系统管理。

3. 在左侧菜单栏选择系统设置 > 自定义配置。
4. 参考下表配置参数。

参数名称	参数配置
浏览器标签名称	请自定义浏览器显示的名称。
浏览器ico图标	请单击图标，选择本地保存的图片文件，单击打开。
平台名称	请自定义AI Stack平台显示的名称。
平台Logo	请单击图标，选择本地保存的图片文件，单击打开。

5. 单击提交。

11.6. API Token管理

本章节介绍如何新增、启用、禁用和删除API Token。

操作步骤

1. 以管理员账号[登录AI Stack控制台](#)。
2. 在顶部菜单中单击系统管理。
3. 在左侧菜单栏选择系统管理 > API Token 管理。
4. 单击新增。
5. 选择有效期后单击确定。
6. 在弹出的提示框上单击确定。



其他操作

API Token创建成功后，您还可以执行以下操作。

任务名称	操作步骤
------	------

启用/禁用API Token	? 说明 API Token创建成功后，默认直接启用，如果需要执行启用操作，请先禁用API Token。 1. 单击操作列禁用/启用。 2. 在弹出的提示框上单击确定。
删除API Token	1. 单击操作列删除。 2. 在弹出的提示框上单击确定。

11.7. 网关API Key管理

本章节及其子章节介绍网关API-Key 的创建、编辑、启用禁用、重置等操作，用于网关服务的访问鉴权。

?

说明

该功能不支持多机版版本使用。

11.7.1. API列表

本章节介绍创建、复制、编辑、禁用网关API Key操作。

操作步骤

1. 以管理员账号[登录AI Stack控制台](#)。

2. 在顶部菜单中单击系统管理。

3. 在左侧菜单栏选择系统管理 > 网关 API Key 管理。

4. 在API-Key列表页签，单击创建API-Key，参考下表配置参数。

参数名称	参数说明
名称	请自定义名称，由字母、数字、下划线、短划线组成，长度为 1~64 个字符。
用户	API Key绑定的用户，只有被绑定的用户才有权限使用。
描述	请输入API Key的其他信息，例如：用途。
是否启用	默认开启，单击后关闭，

是否启用过期时间	默认关闭，单击后开启过期时间。如果不开启的话，API Key将永不过期。
过期时间	启用过期时间后，需要配置。 设置API Key具体的过期时间，例如：2026-05-22 00:00:00。

5. 单击确定。

相关操作

API Key创建成功后，您还可以执行以下操作。

任务名称	操作步骤
复制API Key	单击操作列复制。
编辑API Key	1. 单击操作列编辑。 2. 修改参数后单击确定。
禁用/启用API Key	1. 单击操作禁用/启用。 2. 在弹出来的提示框上单击确定。
重置API Key	1. 单击操作列 ...。 2. 选择重置，重置后原有 Key 将失效，需要使用新 Key 进行访问。 3. 在弹出的提示框上单击确定。
绑定API Key	1. 单击操作列 ...。 2. 选择绑定。 3. 下拉选择网关，单击确定。
解绑API Key	1. 单击操作列 ...。 2. 选择绑定。 3. 下拉选择网关，单击确定。
删除API Key	1. 单击操作列 ...。 2. 选择删除。 3. 在弹出的提示框上单击确定。

11.7.2. 调用明细

本章节介绍查看网关API Key的调用明细。

操作步骤

1. 以管理员账号[登录AI Stack控制台](#)。
2. 在顶部菜单中单击系统管理。
3. 在左侧菜单栏选择系统管理 > 网关 API Key 管理。
4. 选择调用明细页签，展示总调用次数、总Token、输入总Token和输出总Token以及调用明细。

网关 API-Key 管理

管理网关 API-Key 的创建、编辑、启用禁用、重置等操作。用于网关服务的访问鉴权。

API-Key 列表 调用明细 配置管理

调用汇总

总调用次数

1,949,257 次

总 Token

204,809,026

输入总 Token

11,640,437

输出总 Token

193,168,589

调用明细

2026-05-22 16:38:02

2026-05-25 16:38:02

🔍

全部 API-Key

RequestID	API-Key	网关	用户	请求IP	状态码	调用时间	耗时(ms)	TTFB(ms)	输入Token	输出Token
092d21ad-2284-48cc-b02a-bc7162...	test-zh-71652225	xytest	admin	10.17.1.1	404	2026-05-25 15:48:08	3	3	0	0
0654016-ee1d-44d1-adf7-e95780...	test-zh-71652225	xytest	admin	10.17.14.2	200	2026-05-25 15:48:05	3	3	0	0
1a901763-5a57-4261-9684-e71d0...	test-zh-71652225	xytest	admin	10.236.221.1	404	2026-05-25 15:47:48	4	4	0	0
0ab12616-144b-48b2-a8e9-50230...	test-zh-71652225	xytest	admin	10.236.221.1	404	2026-05-25 15:45:59	2	2	0	0
bf6958fd-d16f-49bf-9724-c271d4d...	test-zh-71652225	xytest	admin	10.236.221.1	404	2026-05-25 15:45:42	2	2	0	0
0589b6ce-c40b-43e0-9f54-86270a...	test-zh-71652225	xytest	admin	10.236.221.1	404	2026-05-25 15:34:34	2	2	0	0
8878aa17-e54b-46c0-a6b6-be09aa...	test-zh-71652225	xytest	admin	10.236.221.1	404	2026-05-25 15:33:18	3	3	0	0

11.7.3. 配置管理

本章节介绍网关服务的配置。在使用网关服务API Key调用时将生效。

操作步骤

1. 以管理员账号[登录AI Stack控制台](#)。
2. 在顶部菜单中单击系统管理。
3. 在左侧菜单栏选择系统管理 > 网关 API Key 管理。
4. 选择配置管理页签。
5. 设置网关服务端口、调用数据最大保存条数和调用数据最大保存天数。
6. 单击提交。

12. 多机版本


12.1. 控制台切换

背景信息

- AI Stack控制台单机版和多机版下模型网关、在线服务信息互相不可见。
- 当AI Stack节点加入多机后，不能创建单机在线服务。
- 单个AI Stack节点允许自身构成多机。

前提条件

1. 以管理员用户[登录AI Stack控制台](#)。
2. 在工作台左上角菜单栏进行多机版和单机版的切换。



3. 在弹出的下拉框单击选择**多机版**，进入AI Stack多机版控制台界面。

12.2. 创建多机集群

背景信息

- AI Stack控制台单机版和多机版下模型网关、在线服务信息互相不可见。
- 当AI Stack节点加入多机后，不能创建单机在线服务。
- 单个AI Stack节点允许自身构成多机。

操作步骤

1. 以管理员用户[登录AI Stack控制台](#)并切换为多机版控制台。
2. 在顶部菜单栏选择**资源管理**。
3. 在左侧导航栏，单击**集群管理**。
4. 单击左上角的**创建集群**，进入AI Stack多机版集群创建界面。

i.

配置项	是否必选	说明
集群名称	是	创建多机版集群的名称。
节点IP	是	加入多机版集群内节点的IP。
网关端口	是	表示连接节点的端口号。
用户名	是	加入多机版集群内节点的管理员账号用户名。
密码	是	加入多机版集群内节点的管理员账号密码。
CPN虚拟IP	否	如果不是CPN节点则无需填写。

5. 单击**确定**，即可创建一个包含上述节点的多机集群。

多机版创建集群后在工作台显示数据始终是多机版数据，与是否切换为单机版无关。

12.3. 扩容多机集群

背景信息

- AI Stack控制台单机版和多机版下模型网关、在线服务信息互相不可见。
- 当AI Stack节点加入多机后，不能创建单机在线服务。
- 单个AI Stack节点允许自身构成多机。

操作步骤

1. 以管理员用户[登录AI Stack控制台](#)并切换为多机版控制台。
2. 在顶部菜单栏中选择**资源管理**。
3. 在左侧导航栏单击**集群管理**。
4. 单击集群操作栏的**扩容**，进入AI Stack多机版集群扩容界面。

配置项	是否必选	说明
节点IP	是	加入多机版集群内节点的IP。
网关端口	是	表示连接节点的端口号。

用户名	是	加入多机版集群内节点的管理员账号用户名。
密码	是	加入多机版集群内节点的管理员账号密码。
CPN虚拟IP	否	如果不是CPN节点则无需填写。

5. 单击**确定**，即可在已有多机集群扩容上述节点。

12.4. 缩容多机集群

背景信息

- AI Stack控制台单机版和多机版下模型网关、在线服务信息互相不可见。
- 当AI Stack节点加入多机后，不能创建单机在线服务。
- 单个AI Stack节点允许自身构成多机。
- 当多机集群内只存在一个节点时，缩容节点操作等同于删除多机集群。

操作步骤

1. 以管理员用户[登录AI Stack控制台](#)并切换为多机版控制台。
2. 在顶部菜单栏中选择**资源管理**。
3. 在左侧导航栏单击**集群管理**。
4. 单击集群操作栏的**缩容**，进入AI Stack多机版集群缩容界面。
在**节点列表**中选择要缩容的节点。

配置项	是否必选	说明
节点列表	是	要缩容的多机版集群内节点的信息。
节点IP	是	要缩容的多机版集群内节点的IP。

5. 单击**确定**按钮，即可在已有多机集群缩容上述节点。

12.5. 删除多机集群

背景信息

- AI Stack控制台单机版和多机版下模型网关、在线服务信息互相不可见。
- 当AI Stack节点加入多机后，不能创建单机在线服务。
- 单个AI Stack节点允许自身构成多机。
- 当多机集群内只存在一个节点时，缩容节点操作等同于删除多机集群。

操作步骤

1. 以管理员用户登录AI Stack控制台并切换为多机版控制台。
2. 在顶部菜单栏中选择资源管理。
3. 在左侧导航栏单击集群管理。
4. 单击集群操作栏的删除。
5. 单击确定按钮，即可删除已有多机集群。

12.6. 多机在线服务

背景信息

- AI Stack控制台单机版和多机版下模型网关、在线服务信息互相不可见。
- 当AI Stack节点加入多机后，不能创建单机在线服务。
- 单个AI Stack节点允许自身构成多机。

前提条件

已成功登录AI Stack控制台并且节点已在多机集群内。

操作步骤

1. 以管理员用户登录AI Stack控制台并切换为多机版控制台。
2. 在顶部菜单栏中选择推理服务。
3. 在左侧菜单栏选择推理服务 > 在线服务。
4. 单击左上角的部署服务，进入AI Stack多机版在线服务创建界面。
 - i.

配置项	是否必选	说明
服务名称	是	创建多机版在线推理服务的名称。
描述	否	创建多机版在线推理服务的描述。
节点列表	是	在线推理服务所部署的多机集群的节点。
模型服务配置	是	支持推荐配置和自定义配置。
实例规格	是	支持基础配置、标准配置和专业配置
模型	是	在线服务依托的具体底层模型。

ii. 当模型服务配置选择自定义配置时，会引入新的配置项。

配置项	是否必选	说明
服务端口	是	在线服务暴露的端口。
CPU数量	是	部署在线服务时使用的CPU数量。
内存容量	是	部署在线服务时使用的内存容量。
GPU数量	是	部署在线服务时使用的GPU数量。
共享内存容量	否	部署在线服务时使用的共享内存。
选择模型	是	部署在线服务时使用底层模型。
选择镜像	是	部署在线服务时使用的推理框架镜像。
启动命令	是	部署在线服务需要运行的启动命令。
是否启用API Key	是	部署在线服务是否开启API Key保证推理服务安全。
API Key	是	若启用API Key则输入。

5. 单击创建按钮，即可创建一个包含上述节点列表的多机集群在线服务。

12.7. 多机模型网关

背景信息

- AI Stack控制台单机版和多机版下模型网关、在线服务信息互相不可见。
- 当AI Stack节点加入多机后，不能创建单机在线服务。
- 单个AI Stack节点允许自身构成多机。
- AI Stack多机版控制台下至少存在一个多机版在线推理服务。

前提条件

已成功登录AI Stack控制台并且节点已在多机集群内。

操作步骤

1. 以管理员用户登录AI Stack控制台并切换为多机版控制台。
2. 在顶部菜单栏中选择推理服务。

默认进入模型网关页面。

3. 单击左上角的创建模型网关，进入AI Stack多机版模型网关创建界面。

创建智能网关

1 启用智能网关服务需保证接入后端服务的模型名称和API Key一致。

网关名称 *

网关一

网关策略 *

轮询策略

后端服务 *

服务IP *

端口 *

80

+ 添加服务

取消

确定

配置项	是否必选	说明
网关名称	是	模型网关的名称。
网关策略	是	模型网关的负载策略。
后端服务	是	模型网关流量转发的后端服务信息。

4. 单击确定按钮，即可创建一个包含上述节点列表的多机集群在线服务。

12.8. 多机模型观测

本章节介绍在多机版的场景下如何查看模型监测数据。模型观测会展示Token消耗、首Token延时等信息，以便用户了解模型的使用情况和性能变化，从而更有效地进行问题定位、故障排除和性能优化。

前提条件

控制台已切换至多机版，详情请参见[控制台切换](#)。


操作步骤

1. [登录AI Stack控制台](#)。
2. 在顶部菜单栏中单击[推理服务](#)。

3. 在左侧菜单栏中选择推理服务 > 模型观测。



4. 单击操作列监控，可查看单个在线服务状态，包括每分钟输出/生成token数量、总量、首token延迟、并发数据等。



13.附录

13.1. 支持的模型列表

本章节介绍AI Stack支持的模型，表格中所列模型针对ASpeed镜像、ASpeed部署、自定义部署、模型体验均支持，有其他情况会特别说明。

模型类型	模型名称
Qwen	QwQ-32B
	Qwen-Image
	Qwen2.5-32B
	Qwen2.5-72B
	Qwen3-235B-A22B
	Qwen3-235B-A22B-INT8
	Qwen3-235B-A22B-Instruct-2507
	Qwen3-32B
	Qwen3-Coder-480B-A35B-Instruct
	Qwen3-Coder-480B-A35B-Instruct-INT8
	Qwen3-Embedding-8B
	Qwen3-Pro-Instruct-INT8
	Qwen3-Pro-VL-Instruct-INT8
	Qwen3.5-122B-A10B
	Qwen3.5-122B-A10B-INT8

	Qwen3.5-35B-A3B-INT8
	Qwen3.5-397B-A17B
	Qwen3.5-397B-A17B-INT8
	Qwen3.6-27B
	Qwen3.6-35B-A3B
	Qwen3.6-35B-A3B-INT8
	Qwen3.6-Plus-INT8
DeepSeek	DeepSeek-R1-0528-BF16
	DeepSeek-R1-0528-INT8
	DeepSeek-R1-Distill-Qwen-32B
	DeepSeek-V3-0324-BF16
	DeepSeek-V3-0324-INT8
	DeepSeek-V3.1-INT8
	DeepSeek-V3.2-BF16
	DeepSeek-V3.2-INT8
Moonshot	DeepSeek-V4-Flash-INT8
	Kimi-K2.5
	Kimi-K2.6
	GLM-5.1-INT8

ZhipuAI	GLM5-INT8
	GLM-5.1-W4A8
BAAI	bge-reranker-v2-m3
MiniMax	MiniMax-M2.7-INT8

13.2. 禁止多点登录

本章节介绍禁止多点登录的操作，当用户开启禁止多点登录功能后，同一账号只允许一人登录。

操作步骤

1. 登录AI Stack机器节点。
2. 执行以下命令，进入配置文件目录。

```
cd /usr/bin/aioController/config/
```

3. 执行以下命令，编辑配置文件。

```
vi config.yaml
```

将配置文件的SingleSessionEnabled的值改为true，如果配置文件不存在，请复制下面的内容，放在config.yaml中并保存。

```
Server:
  SingleSessionEnabled: true
```

4. 执行以下命令，重启服务使配置生效。

```
systemctl restart aioController
```

5. 使用浏览器不同用户登录同一账号的AI Stack控制台，查看前一用户是否会下线登出。

13.3. 配置域名登录

本章节介绍如何配置域名，配置域名后可通过域名登录AI Stack控制台。

前提条件

- 需要有自己的DNS服务才支持配置域名。
- 请确保每台机器都要配置DNS服务，且多机之间可以通过域名互相访问。
- 请确保每个域名都能正确解析。

操作步骤

⚠ 重要

本操作以给某台机器配置a.aistack.com域名为例介绍，在实际操作中请替换为实际域名。

1. 登录机器节点。
2. 执行以下命令，修改配置。

```
vi /usr/bin/aioController/config/config.yaml
# 新增如下内容，如果已有其他内容就只新增 PublicEndPoint 这一行
Server:
  PublicEndPoint: "a.aistack.com"
```

3. 执行以下命令，删掉cas服务。

```
$ nerdctl stop cas-server && nerdctl rm cas-server
```

4. 执行以下命令，删掉cappservice服务。

```
$ nerdctl stop appservice && nerdctl rm appservice
```

5. 执行以下命令，重启服务。

```
$ systemctl restart aioController
```

6. 执行以下命令，验证DNS配置是否正确。

```
$ nerdctl exec cas-server cat /etc/resolv.conf
$ nerdctl exec appservice cat /etc/resolv.conf
```

7. 参考上述步骤，在每个机器上执行一次。
8. 通过http://域名访问AI Stack控制台，检查连通性。

13.4. 配置HTTPS

本文介绍如何为AIStack控制台及网关服务配置HTTPS协议访问提供说明，并详述证书的相关验证步骤。推理服务通过容器直接暴露接口（端口范围 30000-35000），目前尚不支持HTTPS协议，但可通过智能网关代理实现HTTPS访问。

操作步骤

1. 验证证书。

检查证书文件的格式与内容。证书需要是PEM格式，在nginx.crt文件中应该包含一个或者多个以“-----BEGIN CERTIFICATE-----”开始，以“-----END CERTIFICATE-----”结束的证书。

- i. 如果只包含一个证书，该证书应该指向本机FQDN（Fully Qualified Domain Name）。具体来说，`openssl x509 -in <nginx.crt> -noout -subject` 命令的输出中“CN=<common name>”的<common name>部分应该跟FQDN一致，以及命令 `openssl x509 -in cert.pem -noout -ext subjectAltName` 的输出中应该包含对应本机的以“DNS:”开头的记录（可以是完全匹配FQDN也可以依靠“*”进行通配）。此情况下，该证书可以是自签名的证书，也可以由根CA签发。如果FQDN不匹配则通过浏览器和代码访问时，TLS握手会出错或者告警。
- ii. 如果包含多个证书，需要将对应本机的证书（终端节点 end entity 证书）放在最前面，紧接着是为终端节点签发证书的中间CA（如有）的证书，然后是为中间CA签发证书的上级CA（如有）证书，依次类推，直到根CA证书。该排列顺序是Nginx和TLS协议规定，顺序错误可能会造成TLS握手告警。唯一允许（但不推荐）省略的是根CA证书，省略的前提是所有的客户端都在本地信任根CA。

- iii. 判断证书是否为自签名，或者判断自身的签发者可以用到命令 `openssl x509 -in <cert-file.crt> -noout -issuer -subject`。输出中的“subject=”之后的部分为“subject字符串”，“issuer=”之后的部分为“issuer”字符串。自签名的情况下证书两者一样；CA签发的证书，其issuer字符串等于上级CA的subject字符串。

② 说明

如果证书不是自签名的（`subject != issuer`），需要确认证书链是受信任的。

将证书链拆成本机证书（`ee.crt`）、中间CA证书（`int-ca.crt`）、根CA证书（`root-ca.crt`）三部分。

- 如果三部分都包含，执行命令 `openssl verify -CAfile root-ca.crt -untrusted int-ca.crt -purpose sslserver -x509_strict ee.crt`。
- 如果完整的证书链只有2层，则只有本机证书和根CA证书，执行命令 `openssl verify -CAfile root-ca.crt -purpose sslserver -x509_strict ee.crt`。
- 如果原证书链省略了根CA证书且本机已经默认信任了根CA，则执行命令 `openssl verify -untrusted int-ca.crt -purpose sslserver -x509_strict ee.crt`（如果有中间CA `int-ca.crt` 文件）。如果本机信任的根CA不在openssl默认路径，则需要根据实际情况增加CAfile或者CAPath参数来指定非默认路径的CA。如 `openssl verify -CAfile <custom-ca-file> [-untrusted int-ca.crt] -purpose sslserver -x509_strict ee.crt` 或者 `openssl verify -CAPath <custom-ca-path> [-untrusted int-ca.crt] -purpose sslserver -x509_strict ee.crt`。

无论上述哪个命令，证书链正确的情况下输出都为“`ee.crt: OK`”。不正确的时候则需要根据出错信息来查错。

2. 替换证书。

当前部署后会自带一个有效期为10年的自签名证书，自签名证书不能保证内容的严谨性。如果用户有自己的证书，请替换下面两个文件。

```
# ll /etc/nginx/ssl/
总用量 8
-rw-r--r-- 1 root root 1342 Feb  4 20:49 nginx.crt
-rw----- 1 root root 1679 Feb  4 20:49 nginx.key
```

3. 注意：2.13 版本起默认的 nginx 配置，已对aisatck 服务的 443 端口访问做了预配置，但未启用，因此无需更改额外 nginx 配置。

4. 执行以下命令，修改配置文件。

```
# 配置文件默认不存在，可以通过 touch 新增
# 配置文件更改原则：只增加本次需要的即可，如已有其他配置项，无需进行修改
# 注意yaml文件语法规则，不要用 tab缩进，用两个空格；yaml对空格敏感
$ touch /usr/bin/aioController/config/config.yaml
$ vi /usr/bin/aioController/config/config.yaml
Server:
  {.....其他无关配置}
  TLS: true
  {.....其他无关配置}
```

5. 执行以下命令，重启服务。


```
# 重启appservice，如果没有这个容器可以忽略
nerdctl stop appservice && nerdctl rm appservice
# 重启aioController
systemctl restart aioController
```

6. 证书后置验证。

验证Nginx配置好HTTPS之后测试TLS握手：使用命令 `openssl s_client -connect <fqdn:port>` `</dev/null`，握手正确的时候最终输出为 “`Verify return code: 0 (ok)`”。

- 如果证书链的顺序出错或者有缺失，可以在“Certificate chain”部分进行检查。
- 如果客户使用的是自签名证书，需要的命令为 `openssl s_client -CAfile <nginx.crt> -connect <fqdn:port> </dev/null`。

13.5. 通过AzureAD登录AI Stack

本章节介绍在单机部署和多机部署场景下如何通过AzureAD登录AI Stack。

前提条件

- AzureAD会强制SP服务开启https，请参见[配置HTTPS](#)。
- 目前仅支持admin，因此任何身份用户登录都会签发admin身份。

单机部署

1. 参见[配置HTTPS](#)配置AI Stack的https访问。
2. 通过以下接口获取AI Stack作为SP的配置。

```
https://{AIStackIP}/api/v1/saml2/sp/metadata.xml
```

3. 提前在AzureAD管理界面配置应用，配置关联用户/用户组。

4. 将SP metadata上传到IDP。

主页 > aistack

aistack | 基于 SAML 的登录

企业应用程序

概述

部署计划

诊断并解决问题

管理

属性

所有者

角色和管理员

用户和组

单一登录

预配

应用程序代理

自助服务

自定义安全属性

安全组

活动

疑难解答和支持

设置 SAML 单一登录

基于联盟协议的 SSO 实现改进了安全性、可靠性和最终用户体验，并且更易于实现。对于不使用 OpenID Connect 或 OAuth 的现有应用程序，请尽可能选择 SAML 单一登录。[了解详细信息。](#)

阅读 [配置指南](#) 用于帮助集成 aistack。

1 基本 SAML 配置

标识符(实体 ID) https://10.1...
回复 URL (断言使用者服务 URL) https://10.1.../api/v1/saml2/login
登录 URL 可选
中继状态(可选) 可选
注销 URL (可选) 可选

2 属性和索赔

givenname user.givenname
surname user.surname
emailaddress user.mail
name user.userprincipalname
唯一用户标识符 user.userprincipalname

3 SAML 证书

令牌签名证书
状态 活动
指纹 7F6B1E23D228B03A330A9621E0B474D5E5E909ED
过期 2029/3/19 17:40:24
通知电子邮件 kettlecat6@outlook.com
应用联合元数据 URL https://login.microsoftonline.com/ed12c002-402f...
证书(base64) 下载
证书(Raw) 下载
联合元数据 XML 下载

验证证书(可选)
必需 否

5. 下载IDP metadata元数据。

3 SAML 证书

令牌签名证书

状态 活动
指纹 7F6B1E23D228B03A330A9621E0B474D5E5E909ED
过期 2029/3/19 17:40:24
通知电子邮件 kettlecat6@outlook.com
应用联合元数据 URL https://login.microsoftonline.com/ed12c002-402f...
证书(base64) 下载
证书(Raw) 下载
联合元数据 XML 下载

验证证书(可选)
必需 否
活动 0
过期 0

6. 执行以下命令，将下载的IDP元数据文件上传至环境上。


```
cd /usr/bin/aioController/
# 上传下载的IdP文件到环境上
cp aistack.xml /usr/bin/aioController/config/azure-entraid-aistack.xml

# 编辑配置, 保存
vi config/config.yaml
Server:
  DefaultIDP: AzureAD
  ExternalIDPs:
    "AzureAD": '/usr/bin/aioController/config/azure-entraid-aistack.xml'
```

7. 执行以下命令，重启服务。

```
systemctl restart aioController
```

8. 测试登录是否成功。



登录 ...

↑ 上传元数据文件 更改单一登录模式 测试此应用程序 得到反馈?

设置 SAML 单一登录

基于联盟协议的 SSO 实现改进了安全性、可靠性和最终用户体验，并且更易于实现。对于不使程序，请尽可能选择 SAML 单一登录。[了解详细信息。](#)

阅读 [配置指南](#) 用于帮助集成 aistack。

1

基本 SAML 配置

标识符(实体 ID)	https://10.1...
回复 URL (断言使用者服务 URL)	https://10.1.../api/v1/saml2/
登录 URL	可选
中继状态(可选)	可选
注销 URL (可选)	可选

2

属性和索赔

givenname	user.givenname
surname	user.surname
emailaddress	user.mail
name	user.userprincipalname
唯一用户标识符	user.userprincipalname

3

SAML 证书

令牌签名证书	活动
状态	7F6B1E23D228B03A330A9621E0B...
指纹	2020/3/19 17:40:24
过期时间	

正在测试登录

通过在此处登录来 Test aistack 的单一登录配置。请确保已配置 Microsoft Entra 配置和 aistack 本身。

若要以前用户身份进行测试，请选择下面的“测试登录”。

若要以其他用户身份进行测试，请在浏览器的新选项卡中打开此体验。在该新选项卡中，使用要测试登录身份的用户登录后，在该新选项卡中，选择“测试登录”以便以该用户身份进行测试。[阅读测试指南了解详细信息。](#)

测试登录

解决错误

如果在登录页中遇到错误，请将其粘贴在下方。如果仍然看到同一问题，请等待几分钟，然后重试。

[错误如何呈现?](#)

请求 ID: 4f8ec053-fb71-47de-a010-2786a32f1900
相关 ID: 5aa879f5-68f1-482a-a405-f993d8f4cb0
时间戳: 2018-03-06T23:54:10Z
消息: 错误 AADSTSXXXX:

[获取解决方案指南](#)

9. 登录成功，用户身份为admin。

10. 访问AI Stack控制台https://IP。

- 如果未登录会跳转至Azure AD登录页。
- 登录成功后会跳转至AI Stack页面；如果Azure AD登录状态仍有效，会直接跳至AI Stack页面。

多机部署

多机版部署场景请参考单机版部署将每个机器依次配置一次，即可通过AzureAD登录AI Stack。